

به نام خدا



دانشکده مهندسی کامپیوتر

نام درس: علوم داده

نام استاد: دکتر نادری

پروژه تحلیل اکتشافی داده‌ها بر روی مجموعه داده‌های ETF

اعضای گروه:

نیوشا یقینی، ۹۸۵۲۲۳۴۶

غزل عربعلی، ۹۷۵۲۱۳۹۶

تاریخ: آذر/۱۴۰۳

فهرست مطالب

فصل ۱.	مقدمه.....	۴
۱,۱.	هدف پروژه.....	۴
۱,۲.	معرفی ETFها و اهمیت آنها در بازار مالی.....	۵
۱,۳.	ساختار گزارش.....	۶
فصل ۲.	شناخت داده‌ها.....	۷
۲,۱.	منبع داده‌ها.....	۷
۲,۲.	ساختار داده‌ها.....	۷
۲,۳.	دسته بندی ETFها.....	۸
فصل ۳.	پیش پردازش داده‌ها.....	۱۰
۳,۱.	پاک سازی داده‌ها (حذف ستون‌های نامربوط، اصلاح نوع داده‌ها، و حذف مقادیر خالی).....	۱۰
۳,۲.	شناسایی و حذف نقاط پرت.....	۱۰
۳,۳.	دسته بندی داده‌ها.....	۱۵
فصل ۴.	تحلیل داده‌ها.....	۱۷
۴,۱.	تحلیل آماری.....	۱۷
۴,۲.	تحلیل تک بعدی.....	۲۱
۴,۳.	تحلیل دوبعدی.....	۲۲
۴,۴.	تحلیل سه بعدی.....	۲۴
۴,۵.	تحلیل سری زمانی.....	۲۵
فصل ۵.	خوشه بندی.....	۲۶
۵,۱.	مقدمه ای بر خوشه بندی.....	۲۶
۵,۲.	روش خوشه بندی.....	۲۶
۵,۳.	تعیین تعداد خوشه‌ها.....	۲۷
۵,۴.	اجرای خوشه بندی بر روی داده‌های ETF.....	۳۸
۵,۵.	بصری سازی نتایج خوشه بندی.....	۲۸
۵,۶.	تحلیل نتایج خوشه بندی.....	۲۸
فصل ۶.	مقایسه ETFها.....	۳۰
۶,۱.	مقایسه بازدهی کل.....	۳۰
۶,۲.	مقایسه نوسانات.....	۳۰
۶,۳.	مقایسه روندهای قیمتی.....	۳۱
۶,۴.	مقایسه همبستگی.....	۳۱
۶,۵.	تحلیل خوشه بندی.....	۳۱
۶,۶.	نتیجه گیری.....	۳۲

۱ مقدمه

در دنیای امروز، صندوق‌های سرمایه‌گذاری قابل معامله (ETF) به یکی از ابزارهای اصلی سرمایه‌گذاری در بازارهای مالی تبدیل شده‌اند. این ابزارها به سرمایه‌گذاران این امکان را می‌دهند تا با هزینه کمتر، تنوع بیشتری در دارایی‌های خود ایجاد کنند و در عین حال از مزایای نقدشوندگی بالا و امکان معامله در طول روز بهره‌مند شوند.

این پروژه به تحلیل و مقایسه رفتار سه نوع مختلف از ETFها پرداخته است. این ETFها شامل **GLD**^۱ و **QQQ**^۲ می‌باشند.

در این گزارش، ویژگی‌های این سه ETF از جنبه‌های مختلفی مانند بازدهی، نوسانات و روندهای قیمتی بررسی خواهد شد. برای تحلیل این داده‌ها، از **تحلیل اکتشافی داده‌ها (EDA)** استفاده شده است که به شناسایی الگوهای نهفته در داده‌ها کمک می‌کند و رفتار هر ETF را به دقت بررسی می‌کند.

علاوه بر استفاده از روش‌های استاندارد برای تحلیل‌های مختلف مانند پاکسازی داده‌ها، تحلیل‌های آماری، خوشه‌بندی و دیگر موارد، در برخی مراحل از **روش‌های خلاقانه و ابتکاری** نیز استفاده شده است. به عنوان مثال، در بخش حذف **outlier**ها، یک روش ابتکاری برای شناسایی و حذف داده‌های غیرعادی معرفی شده که به بهبود دقت نتایج تحلیل کمک می‌کند.

هدف این پروژه تحلیل دقیق عملکرد این ETFها و شناسایی تفاوت‌ها و شباهت‌ها در رفتار آنها است. بر اساس این تحلیل‌ها، پیشنهاداتی برای سرمایه‌گذاری به خوانندگان و سرمایه‌گذاران ارائه خواهد شد.

۱.۱ هدف پروژه

هدف این پروژه، **تحلیل و مقایسه رفتار سه نوع مختلف از ETFها** است. این پروژه با هدف بررسی بازدهی، نوسانات و روندهای قیمتی سه ETF منتخب انجام شده است که عبارتند از:

- **VT**: نماینده شاخص بازارهای جهانی.
- **GLD**: نماینده بازار کالاها با تمرکز بر طلا.
- **QQQ**: نماینده سهام فناوری در شاخص Nasdaq-100.

اهداف این پروژه عبارتند از:

۱. **تحلیل داده‌ها**: بررسی ویژگی‌های هر ETF از جنبه‌های مختلف.
۲. **مقایسه ETFها**: شناسایی تفاوت‌ها و شباهت‌ها در عملکرد این سه ETF.
۳. **ارائه توصیه‌های سرمایه‌گذاری**: بر اساس نتایج تحلیل‌ها، ارائه پیشنهادات برای سرمایه‌گذاران.

^۱ Exchange-Traded Fund

^۲ Vanguard Total World Stock

^۳ SPDR Gold Shares

^۴ Invesco QQQ Trust

۱.۲ معرفی ETFها و اهمیت آنها در بازار مالی

ETFها نوعی از صندوق‌های سرمایه‌گذاری هستند که در بورس اوراق بهادار معامله می‌شوند. به عبارت دیگر، آنها مشابه سهام هستند، اما به جای نمایندگی یک شرکت خاص، شامل مجموعه‌ای از دارایی‌ها مانند سهام، اوراق قرضه، کالاها یا سایر انواع دارایی‌ها می‌باشند.

ETFها به سرمایه‌گذاران این امکان را می‌دهند که با خرید یک واحد از صندوق، به طور همزمان در مجموعه‌ای از دارایی‌ها سرمایه‌گذاری کنند. این ویژگی باعث می‌شود که **ETF**ها به عنوان ابزاری با تنوع بالا و ریسک کمتری نسبت به سرمایه‌گذاری در یک دارایی خاص شناخته شوند. علاوه بر این، **ETF**ها مزایای متعددی دارند که آنها را به ابزاری محبوب در بازارهای مالی تبدیل کرده است:

۱. **تنوع بالا** **ETF**ها: به سرمایه‌گذاران امکان می‌دهند با خرید یک واحد، در یک مجموعه متنوع از دارایی‌ها سرمایه‌گذاری کنند.
۲. **کاهش هزینه**: مدیریت **ETF**ها معمولاً هزینه کمتری نسبت به صندوق‌های سرمایه‌گذاری سنتی دارد.
۳. **نقدشوندگی بالا** **ETF**ها: در بازارهای مالی به راحتی قابل خرید و فروش هستند.
۴. **انعطاف‌پذیری** **ETF**ها: می‌توانند شاخص‌ها، کالاها یا صنایع خاص را دنبال کنند.

علت انتخاب این **ETF**ها:

در این پروژه، سه **ETF** منتخب برای تحلیل و مقایسه انتخاب شده‌اند که هر کدام نماینده بخش خاصی از بازار مالی هستند. انتخاب این **ETF**ها به دلایل زیر انجام شده است:

- **VT**: این **ETF** نماینده شاخص بازارهای جهانی است و عملکرد کلی بازارهای سهام را در سطح جهانی منعکس می‌کند. انتخاب این **ETF** به ما این امکان را می‌دهد که عملکرد کلی بازارهای جهانی را در نظر بگیریم.
- **GLD**: این **ETF** نماینده بازار کالاها است و به طور خاص به طلا متمرکز است. رفتار مستقل از سهام و تأثیرگذاری آن بر اساس قیمت طلا باعث می‌شود که این **ETF** برای تحلیل رفتار بازار کالاها جذاب باشد.
- **QQQ**: این **ETF** نماینده سهام شرکت‌های فناوری در شاخص Nasdaq-100 است. به دلیل نوسانات و رشد بالای این بخش از بازار، این **ETF** به ما کمک می‌کند تا رفتار بخش فناوری را بهتر درک کنیم.

تحلیل این سه **ETF** به ما این امکان را می‌دهد که رفتار بازار را در دسته‌های مختلف (شاخص‌ها، کالاها و فناوری) بهتر درک کنیم و تأثیرات متقابل آنها را در شرایط مختلف بازار مورد بررسی قرار دهیم.

۱.۳ ساختار گزارش

ساختار گزارش:

این گزارش شامل چندین بخش اصلی است که به تحلیل و مقایسه سه ETF منتخب پرداخته و نتایج مختلف را ارائه می‌دهند. ساختار گزارش به شرح زیر است:

۱. **مقدمه:** در این بخش، به اهمیت و کاربرد ETFها در بازار مالی پرداخته شده و هدف پروژه توضیح داده شده است.
۲. **معرفی داده‌ها:** در این بخش، منبع داده‌ها، ساختار آن‌ها و توضیحاتی در مورد هر یک از ETFها داده شده است.
۳. **پیش‌پردازش داده‌ها:** در این بخش، روش‌های استفاده‌شده برای پاکسازی و آماده‌سازی داده‌ها برای تحلیل توضیح داده می‌شود.
۴. **تحلیل داده‌ها:** شامل تحلیل‌های مختلف از جمله تحلیل تک‌بعدی، دوبعدی، سه‌بعدی و تحلیل سری زمانی است. این تحلیل‌ها در نوت‌بوک‌های جداگانه انجام شده‌اند و نتایج هر کدام به‌طور دقیق و واضح ارائه شده است.
۵. **خوشه‌بندی:** در این بخش، از روش‌های خوشه‌بندی برای شناسایی الگوها و گروه‌بندی ETFها استفاده شده است. نتایج خوشه‌بندی به تفکیک در نوت‌بوک مربوطه آورده شده و تحلیل‌های مربوط به آن ارائه می‌شود.
۶. **مقایسه ETFها:** در این بخش، تفاوت‌ها و شباهت‌های عملکردی سه ETF منتخب مقایسه شده است.

تمامی نوت‌بوک‌های مربوط به تحلیل‌ها و نتایج در کنار گزارش تحویل داده خواهند شد. در هر نوت‌بوک، کدها، نتایج تحلیل‌ها و بصری‌سازی‌های مربوطه آورده شده و تحلیل‌های مختص به آن‌ها در زیر هر بخش آورده شده است.

کدهای پروژه علاوه بر اینکه در نوت‌بوک‌ها در گزارش گنجانده شده‌اند، از طریق **GitHub** نیز در دسترس هستند.

۲ معرفی داده‌ها

در این پروژه، داده‌ها از دیتاست **Huge Stock Market Dataset** موجود در وبسایت **Kaggle** استخراج شده است. این دیتاست یکی از معتبرترین منابع داده در زمینه بازارهای مالی است که به‌طور گسترده توسط تحلیل‌گران مالی مورد استفاده قرار می‌گیرد. تا کنون، این دیتاست بیش از **121,803** بار دانلود و **1.11** میلیون بار بازدید داشته است و به عنوان یکی از بهترین دیتاست‌های موجود در زمینه تحلیل‌های بازار سهام و ETF شناخته می‌شود.

دیتاست شامل اطلاعات تاریخی قیمت و حجم معاملات برای تمامی سهام و صندوق‌های سرمایه‌گذاری قابل معامله (ETF) در بازارهای مالی ایالات متحده است که در بورس‌های **NYSE**، **NASDAQ** و **NYSE MKT** معامله می‌شوند. این دیتاست از تاریخ **۲۶ جون ۲۰۰۸** تا تاریخ **۱۱ نوامبر ۲۰۱۷** به‌روز رسانی شده است و به فرمت CSV ارائه شده است.

۲.۱ منبع داده‌ها

منبع اصلی داده‌های این پروژه، دیتاست **Huge Stock Market Dataset** موجود در سایت **Kaggle** است. این دیتاست شامل داده‌های روزانه قیمت و حجم معاملات برای سهام و ETFهای مختلف است. مشخصات اصلی این دیتاست به شرح زیر است:

- منبع: وبسایت Kaggle

<https://www.kaggle.com/datasets/borismarjanovic/price-volume-data-for-all-us-stocks-etfs>

- نوع داده‌ها: داده‌های روزانه قیمت باز شدن، بالاترین قیمت، پایین‌ترین قیمت، قیمت بسته‌شدن، و حجم معاملات.
- دوره زمانی: اطلاعات تاریخی چندین سال از بازارهای مالی.
- کاربرد: این داده‌ها می‌توانند برای تحلیل روندهای بازار، بررسی رفتار سهام یا ETFها، و ارزیابی نوسانات استفاده شوند.

این دیتاست در مجموع دارای **8539** فایل است که **1344** فایل از آن مربوط به داده‌های ETFها هستند. اندازه دیتاست تقریباً **809.02 MB** است و در مجموع شامل **2362** رکورد در هر فایل می‌باشد.

۲.۲ ساختار داده‌ها

داده‌های موجود در هر فایل دیتاست شامل ستون‌های مختلفی هستند که به شرح زیر است:

ستون	توضیحات
Date	تاریخ معامله (در فرمت YYYY-MM-DD)
Open	قیمت باز شدن روزانه
High	بالاترین قیمت ثبت‌شده در طول روز
Low	پایین‌ترین قیمت ثبت‌شده در طول روز
Close	قیمت بسته‌شدن روزانه
Volume	حجم کل معاملات انجام‌شده در طول روز
OpenInt	حجم کل معاملات انجام‌شده در طول روز

این ساختار برای تمام ETFها و سهام موجود در دیتاست مشابه است. تعداد رکوردها بستگی به تعداد روزهای معاملاتی دارد و معمولاً شامل داده‌های چندین ساله از بازارهای مالی ایالات متحده است.

۲.۳ دسته بندی ETFها

دیتاست ETFها در سایت Kaggle شامل گروه‌های مختلفی از داده‌ها است که به دسته‌بندی‌های مختلف تقسیم می‌شوند. این دسته‌بندی‌ها به شرح زیر است:

۱. **Index ETFs**: ETFهایی که نماینده شاخص‌های بازار هستند و شامل مجموعه‌ای از سهام در یک شاخص خاص می‌باشند. این دسته از ETFها برای تحلیل کلی بازار و روندهای عمومی بازار مناسب هستند.
۲. **Commodities ETFs**: ETFهایی که شاخص‌هایی از کالاها را دنبال می‌کنند. به عنوان مثال، ETFهایی که قیمت طلا، نفت یا دیگر کالاها را رصد می‌کنند.
۳. **Equity ETFs**: ETFهایی که شامل سهام شرکت‌ها در یک بخش خاص یا شاخص سهام هستند و به طور معمول برای تحلیل صنایع خاص یا سهام شرکت‌های برجسته استفاده می‌شوند.
۴. **Bond ETFs**: این ETFها نماینده اوراق قرضه هستند و برای تحلیل بازار بدهی مناسب می‌باشند.
۵. **Sector ETFs**: ETFهایی که مخصوص یک صنعت خاص مانند تکنولوژی، سلامت یا انرژی هستند.
۶. **Thematic ETFs**: ETFهایی که به موضوعات خاص مانند انرژی‌های تجدیدپذیر، رباتیک، یا بلاک چین می‌پردازند.

در این پروژه، سه ETF منتخب از این مجموعه داده انتخاب شدند که نماینده دسته‌های مختلف ETFها هستند. این ETFها عبارتند از:

1. VT (Vanguard Total World Stock ETF)

- **دسته بندی Index ETF**
- **توضیح VT**: نماینده شاخص بازارهای جهانی است. این ETF شامل ترکیبی از سهام آمریکایی و بین‌المللی است و به عنوان یک شاخص جامع رفتار کلی بازار جهانی را نشان می‌دهد.
- **دلیل انتخاب**:
 - VT رفتار کل بازارهای جهانی را منعکس می‌کند.
 - تحلیل این ETF به شناسایی روندهای کلی در بازار سهام جهانی کمک می‌کند.

2. GLD (SPDR Gold Shares)

- **دسته بندی Commodities ETF**
- **توضیح GLD**: یکی از شناخته‌شده‌ترین ETFها در بازار کالاها است که قیمت طلا را دنبال می‌کند. طلا معمولاً به عنوان یک "پناهگاه امن" در شرایط نوسانات اقتصادی عمل می‌کند.
- **دلیل انتخاب**:
 - تحلیل GLD به بررسی رفتار مستقل کالاها در مقایسه با سهام و شاخص‌ها کمک می‌کند.
 - طلا به عنوان یک دارایی امن در زمان بحران‌های مالی، رفتار متفاوتی نسبت به دیگر دارایی‌ها دارد.

3. *QQQ (Invesco QQQ Trust)*

- دسته‌بندی **Equity ETF**
- توضیح **QQQ**: یکی از محبوب‌ترین ETF‌های بازار است که سهام ۱۰۰ شرکت برتر فناوری در شاخص **Nasdaq** را شامل می‌شود. این ETF نشان‌دهنده رشد و نوآوری‌های صنعت فناوری است.
- دلیل انتخاب:
 - **QQQ** به دلیل نوسانات بالا و بازدهی بالقوه زیاد، برای مقایسه با ETF‌های پایدارتر مانند **VT** و **GLD** مناسب است.
 - تحلیل **QQQ** به درک بهتر تأثیر فناوری در بازار کمک می‌کند.

نتیجه‌گیری:

دیتاست موجود در **Kaggle** شامل داده‌های متنوع از ETF‌ها است که به دسته‌های مختلف بازار (شاخص‌ها، کالاها، سهام و ...) تعلق دارند. در این پروژه، با انتخاب سه ETF از دسته‌های مختلف شامل **Equity ETF**، **Commodities ETF**، **Index ETF**، به تحلیل و مقایسه رفتار بازار از جنبه‌های مختلف پرداخته شده است. این انتخاب‌ها به ما کمک می‌کنند تا دیدگاه‌های جامعی از روندهای کلی بازار، بازار کالاها و بازار فناوری به دست آوریم.

۳ پیش‌پردازش داده‌ها

پیش‌پردازش^۱ داده‌ها یکی از مهم‌ترین مراحل در تحلیل داده‌ها است که به بهبود کیفیت، دقت، و تفسیر نتایج کمک می‌کند. این فصل شامل تمام مراحل پیش‌پردازش انجام‌شده در فایل `{ETF_name}_EDA_PreProcess.ipynb` است که همراه با توضیحات و تحلیل نتایج هر بخش و همچنین نمایش‌های گرافیکی برای هر مرحله ارائه شده است. از میان این مراحل، دو روش جدید برای حذف داده‌های پرت به‌عنوان نوآوری‌های اصلی ما معرفی شده‌اند:

1. **Density-Based Method**
2. **Adaptive Skewness-Based Outlier Filtering (ASBOF)**

این گزارش به تفصیل مراحل پیش‌پردازش شامل پاک‌سازی داده‌ها^۲، حذف داده‌های پرت^۳، نرمال‌سازی^۴، و دسته‌بندی^۵ را پوشش می‌دهد.

نتایج هر بخش، هم بصورت تکست ذخیره شده‌اند و هم بصورت نمودار مقایسه شده‌اند.

۳.۱ پاک‌سازی داده‌ها

۱. **حذف ستون‌های غیرضروری:** ستون `OpenInt` به دلیل داشتن مقادیر صفر در تمام سطرها حذف شد.
۲. **فرمت‌بندی تاریخ‌ها:** ستون `Date` به فرمت `datetime` تبدیل شد تا دسترسی و استفاده از داده‌ها آسان‌تر شود.
۳. **بررسی مقادیر Null:** داده‌های ما هیچ مقدار `Null` نداشتند، بنابراین نیازی به اقدامات اضافی نبود.

۳.۲ شناسایی و حذف نقاط پرت

داده‌های پرت می‌توانند به‌شدت تحلیل‌ها را تحت تأثیر قرار دهند. با استفاده از نمودارهای **Boxplot**، داده‌های پرت را شناسایی کردیم و برای حذف کردن آنها از روش‌های زیر استفاده شد و نتایج مقایسه شدند، همچنین نتایج در فایل‌های مربوطه ذخیره شدند:

❖ روش IQR

این روش بر اساس فاصله بین چارک اول ($Q1$) و چارک سوم ($Q3$) عمل می‌کند. هر داده‌ای که خارج از محدوده تعیین شده باشد، به عنوان داده پرت شناسایی و حذف می‌شود.

- **مزیت:** روش ساده و کارآمد برای داده‌های با توزیع متقارن.
- **محدودیت:** برای داده‌های با چولگی زیاد مناسب نیست.

نتایج مربوط به این روش در فایل `txt` مربوط به آن ذخیره شده‌اند.

¹ Preprocessing
² Contributions
³ Data Cleaning
⁴ Outliers
⁵ Normalization
⁶ Categorization

❖ روش Percentiles

در این روش، داده‌ها بر اساس چارک‌های مشخصی مانند ۱٪ و ۹۹٪ یا ۵٪ و ۹۵٪ فیلتر شدند. این چارک‌ها به صورت دستی یا خودکار تعیین شدند.

- مزیت: انعطاف‌پذیری بالا برای تعیین محدوده.
- محدودیت: وابستگی به انتخاب دستی درصدها.

نتایج مربوط به این روش در فایل txt مربوط به آن ذخیره شده‌اند.

❖ روش Z-Score

این روش از مقدار استاندارد Z برای شناسایی داده‌های پرت استفاده می‌کند. داده‌هایی که $|Z| > 3$ هستند، حذف شدند.

- مزیت: مناسب برای داده‌هایی با توزیع نرمال.
- محدودیت: عملکرد ضعیف در داده‌های با چولگی زیاد.

❖ روش Density Based – نوآوری اول

این روش برای انجام فیلترینگ داده‌ها بر اساس چگالی (Density-Based Filtering) و اصلاحات پیشرفته از طریق آستانه‌های دینامیک از طریق درصدی از هیستوگرام داده‌ها طراحی شده‌است. هدف اصلی این روش، شناسایی و حذف نقاط داده‌ای است که در نواحی کم‌چگالی قرار دارند و به احتمال زیاد به عنوان نویز یا داده‌های غیرمعتبر شناسایی می‌شوند.

ایده اولیه:

این الگوریتم یک روش مبتنی بر چگالی داده‌ها برای حذف داده‌های پرت و پاکسازی مجموعه داده‌ها است. ایده اصلی بر اساس شناسایی بازه‌هایی از داده‌ها است که تعداد نمونه‌های موجود در آن بازه‌ها بسیار کم است و این کمبود ممکن است نشان‌دهنده وجود داده‌های غیرعادی باشد. این روش با ترکیب اطلاعات چگالی و تحلیل توزیع آماری (مانند چولگی) به صورت دینامیک و با جدول از پیش تعیین شده، عمل می‌کند و درصدهای مورد استفاده و آستانه‌های چگالی را برای حذف داده‌های پرت بهینه‌سازی می‌کند.

توضیحات گام به گام الگوریتم:

۱. محاسبه هیستوگرام^۱: برای هر ستون از داده‌ها (Open, Low, High, Close, Volume)، هیستوگرام با ۲۰ bin محاسبه می‌شود. هیستوگرام نشان‌دهنده توزیع فراوانی داده‌ها در فواصل مختلف است.
۲. محاسبه چولگی^۲: چولگی، معیاری برای نشان دادن نحوه انحراف توزیع داده‌ها از یک توزیع نرمال است. اگر چولگی کمتر از ۱ باشد، توزیع به صورت تقریبی نرمال است. این مقدار برای هر ستون محاسبه می‌شود و به تصمیم‌گیری برای تعیین درصد مورد استفاده در مرحله بعد کمک می‌کند.
۳. تعیین درصد بر اساس چولگی: بر اساس مقدار چولگی برای هر ستون، یک درصد مشخص از هیستوگرام انتخاب می‌شود که نشان‌دهنده درصدی از داده‌هاست که باید در فرآیند فیلترینگ استفاده شود. اگر چولگی کمتر از ۱ باشد، درصد پیش‌فرض ۵۰٪ انتخاب می‌شود.

^۱ Histogram

^۲ Skewness

هر چه چولگی بیشتر یا کمتر باشد (در جهت منفی یا مثبت)، درصد به صورت دینامیک افزایش یا کاهش می‌یابد. این درصد می‌تواند از ۱۰ درصد تا ۹۰ درصد تغییر کند. نتیجه انتخابی قرار است به عنوان معیاری انتخاب شود که در ادامه در صورتی که میانگین داده های هر bin از این مقدار کمتر باشد حذف میشوند (قابل ذکر است که در واقع فاصله میانگین با یک ضریب آستانه در نظر گرفته میشود)

۴. **تعیین ضریب فاصله:** پس از تعیین درصد، یک ضریب در نظر میگیریم، که ادامه برای محاسبه آستانه از آن کمک میگیریم، این ضریب انعطاف الگوریتم را بالا میبرد تا فاصله گروه ها با یک ضریبی از آستانه چگالی در نظر گرفته شوند.
۵. **محاسبه آستانه چگالی دینامیک:** پس از تعیین درصد ضریب فاصله (که در اینجا ۸۰ درصد در نظر گرفته شده است)، آستانه چگالی به عنوان ۸۰ درصد از صدک داده‌های هیستوگرام محاسبه می‌شود. این آستانه، خط مرزی است که داده‌های کم چگالی (که ممکن است نویز باشند) شناسایی می‌شوند.
۶. **شناسایی نواحی کم چگالی:** با استفاده از آستانه چگالی، بین‌هایی که دارای چگالی کمتر از آستانه هستند شناسایی می‌شوند. این نواحی به احتمال زیاد نقاط داده غیرمعتبر یا نویز هستند.
۷. **حذف داده‌ها از نواحی کم چگالی (داده‌های پرت):** در نهایت، داده‌هایی که در نواحی کم چگالی قرار دارند، از دیتافریم حذف می‌شوند.
۸. **ثبت نتایج:** نتایج شامل تعداد داده‌های اولیه، تعداد داده‌های نهایی، درصد داده‌های حذف شده و مقادیر چولگی قبل و بعد از حذف در فایل گزارش ذخیره می‌شود.

این الگوریتم با استفاده از تحلیل چگالی و چولگی توانسته است داده‌های غیرعادی را با روشی پویا و انعطاف‌پذیر حذف کند. مزیت اصلی این روش در قابلیت تنظیم پویا بر اساس ویژگی‌های خاص هر ستون داده‌ها است. این امر منجر به بهبود تقارن توزیع داده‌ها و حذف داده‌های غیرعادی بدون نیاز به تعریف آستانه ثابت می‌شود.

نتایج این بخش تنها از روش IOR ضعیف‌تر عمل کرده‌است.

❖ روش Adaptive Skewness-Based Outlier Filtering (ASBOF) – نوآوری دوم

این الگوریتم که به نام **فیلترینگ تطبیقی مبتنی بر چولگی (ASBOF)** هست نوآوری دوم ما در این گزارش می‌باشد، این یک روش پیشرفته برای شناسایی و حذف نقاط داده‌ای است که به احتمال زیاد نویز هستند یا از الگوی کلی داده‌ها خارج هستند. هدف این روش، بهبود دقت داده‌ها بدون از دست دادن اطلاعات مهم است.

ایده اولیه:

ایده این روش از شناسایی و حذف داده‌های پرت بر اساس توزیع داده‌ها و کاهش چولگی (Skewness) نشأت گرفته است. چولگی نشان‌دهنده عدم تقارن در توزیع داده‌ها است. هدف اصلی این روش کاهش چولگی ستون‌های داده‌ای بصورت دینامیک، با حذف داده‌های پرت، بدون آسیب زدن به ساختار کلی داده‌ها و از دست دادن بیش از حد اطلاعات است. این روش پیشرفته روش قبل است.

پارامترهای الگوریتم:

نام پارامتر	مقدار اولیه	توضیحات
removal_limit	0.10	حداکثر درصد مجاز حذف داده‌ها
initial_percentage	50	درصد اولیه برای محاسبه آستانه داده‌های کم‌تراکم
max_percentage	99	حداکثر درصد مجاز برای افزایش آستانه
slow_improvement_standard	0.05	مقدار حداقل بهبود چولگی برای تغییر گام‌ها
differ_percentage_standard	0.8	نسبت چگالی بازه‌ها برای تعیین پرت‌ها
slow_improvement_termination	0.001	مقدار حداقل بهبود چولگی برای توقف الگوریتم
min_shew_for_algo	1	حداقل مقدار چولگی برای اجرای روش دینامیک
slow_improvement_count_limit	10	تعداد گام‌هایی که در آن بهبود چولگی کمتر از مقدار مشخص باشد
steps	[10, 5, 1]	اندازه گام‌ها برای تغییر درصد آستانه در طول الگوریتم

توضیحات گام به گام الگوریتم:

۱. محاسبه چولگی اولیه برای هر ستون

ابتدا، چولگی هر ستون داده به‌طور جداگانه محاسبه می‌شود. چولگی یک معیار آماری برای سنجش میزان عدم تقارن توزیع داده است.

- اگر چولگی کم ($1 \leq$) باشد، به این معناست که توزیع داده نزدیک به حالت متقارن یا نرمال است.
 - اگر چولگی زیاد ($1 >$) باشد، نشان‌دهنده یک توزیع به‌شدت نامتقارن است که ممکن است شامل مقادیر پرت باشد.
- در این مرحله، ستون‌های داده به دو دسته تقسیم می‌شوند:

- ستون‌هایی که نیاز به فیلتر ساده دارند.
- ستون‌هایی که نیاز به فیلتر دینامیک (الگوریتم ASBOF) دارند.

۲. شروع الگوریتم با درصد اولیه

الگوریتم فیلتر دینامیک برای ستون‌هایی با چولگی بالا آغاز می‌شود.

- ابتدا یک درصد اولیه حذف (مثلاً ۵۰٪ که همان median) تعیین می‌شود.
 - این درصد مشخص می‌کند که چه مقدار از داده‌های پرت (بر اساس چگالی) در گام اول حذف شوند.
 - در گام‌های بعدی، این درصد کاهش می‌یابد (مثلاً به ۱۰٪، ۵٪، و سپس ۱٪)، تا فیلتر کردن دقیق‌تر شود.
- این فرآیند به الگوریتم اجازه می‌دهد در ابتدا داده‌های پرت زیادی را حذف کند و سپس با دقت بیشتری عمل کند.

۳. ایده چگالی و تقسیم داده‌ها به بازه‌ها

برای اعمال فیلتر دینامیک، داده‌ها به صورت یک هیستوگرام تقسیم‌بندی می‌شوند:

- بازه‌های مساوی (مثلاً ۲۰ بازه) برای داده‌ها تعیین می‌شود.
- تعداد داده‌های هر بازه (چگالی) محاسبه می‌شود.
- داده‌هایی که در بازه‌هایی با چگالی کم قرار دارند، به‌عنوان داده‌های پرت در نظر گرفته می‌شوند.
- این داده‌ها بیشتر در لبه‌های توزیع قرار دارند.

۴. اعمال فیلتر اولیه بر اساس چگالی

- با توجه به درصد اولیه حذف، داده‌هایی که در بازه‌های کم‌چگالی قرار دارند، فیلتر می‌شوند.
- بازه‌هایی که تعداد داده‌هایشان کمتر از یک مقدار آستانه هستند، به تدریج خالی می‌شوند.
- این مرحله کمک می‌کند تا داده‌های پرت در همان مراحل اولیه حذف شوند.
- بعد از این مرحله، داده‌های باقی‌مانده دوباره بررسی می‌شوند.

۵. تنظیم گام‌های حذف و کاهش تدریجی درصد

- با هر گام، درصد حذف کاهش می‌یابد. این تنظیم پویا باعث می‌شود که فیلتر دقیق‌تر شود:
- در گام‌های اول، درصد حذف بالا (مثلاً ۵۰٪) است.
- در گام‌های بعدی، درصد حذف به ۱۰٪، ۵٪، و در نهایت ۱٪ کاهش می‌یابد.
- هر بار که درصد حذف کاهش می‌یابد، چگالی داده‌های باقی‌مانده دوباره محاسبه شده و داده‌های پرت حذف می‌شوند.

۶. بررسی چولگی و توزیع داده‌ها پس از هر گام

بعد از هر مرحله حذف، موارد زیر بررسی می‌شوند:

۱. چولگی ستون:

- آیا چولگی کاهش یافته است؟
- آیا توزیع داده بهبود یافته و متقارن‌تر شده است؟

۲. توزیع بازه‌ها:

- آیا بازه‌های کم‌چگالی حذف شده‌اند؟
 - آیا داده‌های پرت بیشتری باقی مانده‌اند؟
- اگر توزیع داده بهبود یابد، الگوریتم ادامه پیدا می‌کند. در غیر این صورت، الگوریتم متوقف می‌شود.

۷. شروط خاتمه الگوریتم

الگوریتم تا زمانی که یکی از شروط زیر برقرار نشود، ادامه پیدا می‌کند:

۱. افزایش چولگی:
 - اگر چولگی ستون بعد از حذف داده‌ها افزایش یابد، نشان‌دهنده عملکرد نامناسب فیلتر است و الگوریتم خاتمه می‌یابد.
 ۲. کاهش چولگی ناچیز:
 - اگر کاهش چولگی در چند مرحله متوالی به مقدار کم (مثلاً کمتر از ۰,۰۰۱) برسد، الگوریتم متوقف می‌شود.
 ۳. حذف بیش از ۱۰٪ داده‌ها:
 - اگر تعداد داده‌های حذف‌شده از نصف داده‌های اولیه بیشتر شود، الگوریتم متوقف می‌شود.
۸. ثبت نتایج:

نتایج شامل تعداد داده‌های اولیه، تعداد داده‌های نهایی، درصد داده‌های حذف‌شده و مقادیر چولگی قبل و بعد از حذف در فایل گزارش ذخیره می‌شود.

۳.۳ نرمال‌سازی داده‌ها

داده‌ها برای اطمینان از مقیاس‌بندی یکسان، نرمال‌سازی شدند.

- اهمیت:
 - بهبود عملکرد در الگوریتم‌های خوشه‌بندی و یادگیری ماشین.
 - حذف تأثیر مقیاس‌های مختلف در تحلیل داده‌ها.
- نتیجه: داده‌های نرمال‌شده در فایل CSV جداگانه ذخیره شدند.

۳.۴ دسته‌بندی داده‌ها

به دلیل تمایز زیاد داده‌ها، آن‌ها را دسته‌بندی کردیم. برای این کار از قوانین زیر استفاده شد:

۱. **Sturges' Rule**: تعداد bins را بر اساس $\log_2(n) + 1$ تعیین می‌کند.
 ۲. **Freedman-Diaconis Rule**: تعداد bins بر اساس IQR و اندازه داده تعیین شد.
 ۳. **Scott's Rule**: تعداد bins بر اساس انحراف معیار داده تعیین شد.
 ۴. **Rice Rule**: تعداد bins برابر $2 \times n^{3/5}$ محاسبه شد.
- نتیجه: از ترکیب نتایج Scott و Freedman-Diaconis استفاده شد، زیرا منجر به توزیع متعادل‌تر داده‌ها شد.

۳.۵ ذخیره‌سازی و بازیابی داده‌ها

- مشکل: هنگام ذخیره‌سازی داده‌های دسته‌بندی‌شده به صورت CSV، نوع داده‌ها از category به object تغییر کرد.
- راه حل‌ها:

۱. تبدیل ستون‌ها به category هنگام خواندن فایل.
۲. استفاده از فرمت‌های pickle یا parquet برای حفظ نوع داده.

نتیجه‌گیری:

این فصل پردازش شامل روش‌های استاندارد و پیشرفته برای پاک‌سازی و تحلیل داده‌ها بود. با معرفی دو روش جدید برای حذف داده‌های پرت و دسته‌بندی دقیق داده‌ها، توانستیم مجموعه داده‌ای تمیز و قابل اعتماد ایجاد کنیم که آماده استفاده در مراحل بعدی تحلیل است.

۴ تحلیل داده‌ها

تحلیل داده‌ها یکی از مهم‌ترین مراحل در فرآیند کار با داده‌ها است که به درک بهتر ویژگی‌ها، الگوها، و روابط موجود در داده‌ها کمک می‌کند. این فصل با تمرکز بر رویکردهای مختلف تحلیل، از روش‌های آماری تا بررسی روابط پیچیده‌تر بین متغیرها، به ارائه ابزارها و تکنیک‌هایی می‌پردازد که امکان استخراج بینش‌های معنادار از داده‌ها را فراهم می‌کند.

مطالب این فصل شامل تحلیل آماری برای شناسایی ویژگی‌های اساسی داده‌ها، تحلیل تک‌بعدی برای بررسی توزیع متغیرهای مستقل، تحلیل دوبعدی برای کشف روابط بین دو متغیر، تحلیل سه‌بعدی برای مطالعه روابط پیچیده‌تر، و تحلیل سری زمانی برای بررسی تغییرات داده‌ها در طول زمان است. هر یک از این بخش‌ها ابزارها و روش‌های خاص خود را ارائه می‌دهند که به کاربران کمک می‌کند داده‌ها را به‌طور جامع‌تر بررسی کنند و به نتایج عملی دست یابند.

۴.۱ تحلیل آماری

در این بخش، به تحلیل آماری مجموعه داده‌های مالی خود که شامل داده‌های بازار بورس است، پرداخته‌ایم. تحلیل آماری پایه‌ای برای درک ساختار داده‌ها و شناسایی الگوها یا ناهنجاری‌های معنادار است. ما چندین تحلیل آماری اساسی را برای شناسایی توزیع داده‌ها، روابط بین متغیرها و رفتار کلی بازار انجام داده‌ایم.

این تحلیل‌ها بر روی مجموعه داده پاکسازی‌شده‌ای انجام شده است که در فصل قبلی آماده‌سازی شده است، بنابراین هیچ داده‌ای با مقادیر گم‌شده یا خطاهای آشکار باقی نمانده است. نتایج و نمودارهای مرتبط با این بخش در فایل `{ETF_name}_EDA_Statistical_analysis` قرار داده شده‌اند.

❖ آمار توصیفی

آمار توصیفی^۱ اولین گام در تحلیل آماری ما بود که برای خلاصه‌سازی و درک ویژگی‌های کلیدی مجموعه داده استفاده شد. برای هر ستون، معیارهای زیر محاسبه شد:

- تعداد^۲
- میانگین^۳
- انحراف معیار^۴
- حداقل^۵ و حداکثر^۶
- چارک‌ها^۷

این آمارها یک نمای کلی از مجموعه داده فراهم کرده و به شناسایی ناهنجاری‌ها و درک گرایش مرکزی و پراکندگی داده‌ها کمک کردند. برای دیتاست اولیه، و دیتاست دسته‌بندی شده آن را اعمال کردیم.

¹ Descriptive Statistics

² Count

³ Mean

⁴ Standard Deviation

⁵ Min

⁶ Maximum

⁷ Quartiles

❖ تحلیل نمودار Boxplot

برای ارزیابی تصویری توزیع داده‌ها و شناسایی مقادیر پرت احتمالی، نمودارهای boxplot برای متغیرهای کلیدی ترسیم شد. از آنجا که مجموعه داده از قبل پاکسازی شده بود، این مرحله عمدتاً تأیید کرد که مقادیر پرت شدیدی در داده‌ها وجود ندارد و توزیع داده‌ها به خوبی نمایش داده شد.

❖ تحلیل چولگی و کشیدگی (Skewness and Kurtosis Analysis)

- **چولگی (Skewness)** میزان عدم تقارن توزیع داده را اندازه‌گیری می‌کند. چولگی برابر با ۰ نشان‌دهنده توزیع کاملاً متقارن است، در حالی که چولگی مثبت یا منفی به معنای کشیدگی دم به سمت راست یا چپ است.
- **کشیدگی (Kurtosis)** میزان "دم‌دار بودن" توزیع داده را مشخص می‌کند. کشیدگی بالا نشان‌دهنده دم‌های سنگین‌تر و کشیدگی پایین نشان‌دهنده دم‌های سبک‌تر نسبت به توزیع نرمال است.

بررسی چولگی و کشیدگی به دلایل زیر اهمیت دارد:

۱. **ارزیابی نرمال بودن توزیع:** توزیع نرمال دارای چولگی نزدیک به ۰ و کشیدگی نزدیک به ۳ است.
۲. **انتخاب مدل:** بسیاری از مدل‌های آماری فرض نرمال بودن داده‌ها را دارند؛ انحراف از این فرض ممکن است نیاز به تبدیل داده‌ها یا استفاده از روش‌های جایگزین داشته باشد.
۳. **تحلیل ریسک:** در داده‌های مالی، چولگی و کشیدگی می‌توانند نشان‌دهنده وجود ریسک‌های افراطی یا فرصت‌های غیرمنتظره باشند.

❖ آزمون‌های فرضیه آماری (Statistical Hypothesis Testing)

در این بخش، آزمون‌های آماری زیر برای ارزیابی ویژگی‌های داده‌ها و بررسی فرضیه‌ها انجام شد:

آزمون Shapiro-Wilk

- **هدف:** بررسی اینکه آیا داده‌ها از توزیع نرمال پیروی می‌کنند.
- **کاربرد:** در ارزیابی پیش‌فرض‌های موردنیاز برای آزمون‌های پارامتری استفاده می‌شود.
- **خروجی:** مقدار p ؛ اگر کمتر از ۰,۰۵ باشد، فرض نرمال بودن رد می‌شود.

آزمون Kolmogorov-Smirnov

- **هدف:** مقایسه توزیع نمونه با یک توزیع مرجع (مثلاً توزیع نرمال).
- **کاربرد:** برای شناسایی تفاوت بین توزیع‌ها استفاده می‌شود.
- **خروجی:** مقدار p برای پذیرش یا رد فرضیه صفر.

آزمون T-Test

- **هدف:** مقایسه میانگین دو گروه برای تعیین اختلاف معنادار.
- **کاربرد:** مناسب برای مقایسه عملکرد دو سهم یا گروه.

- انواع: یک نمونه‌ای، دو نمونه‌ای، و جفتی.

آزمون ANOVA

- هدف: بررسی برابری میانگین‌های چند گروه.
- کاربرد: برای مقایسه گروه‌های متعدد در بازار بورس.
- خروجی: مقدار p و F -statistic؛ مقادیر معنادار نشان‌دهنده تفاوت میانگین گروه‌ها است.

❖ تحلیل همبستگی (Correlation Analysis)

همبستگی Spearman

- هدف: اندازه‌گیری روابط یکنواخت (مانند روابط غیرخطی اما ترتیبی) بین متغیرها.
- کاربرد: مناسب برای داده‌هایی که رتبه‌بندی شده یا غیر پارامتری هستند.

همبستگی Pearson

- هدف: اندازه‌گیری روابط خطی بین متغیرها.
- کاربرد: معمولاً برای درک وابستگی خطی بین قیمت‌ها استفاده می‌شود.

• مقایسه:

- Pearson بر خطی بودن تمرکز دارد، در حالی که Spearman روابط یکنواخت را شناسایی می‌کند.
- هر دو معیار دیدگاه‌های مکملی درباره قدرت و جهت روابط ارائه می‌دهند.

ماتریس همبستگی

ماتریس همبستگی، همبستگی جفتی بین تمام متغیرها را خلاصه می‌کند و نمای کاملی از وابستگی متغیرها ارائه می‌دهد.

نقشه حرارتی ماتریس همبستگی

برای بهبود خوانایی، ماتریس همبستگی با استفاده از نقشه حرارتی نمایش داده شد. این نمایش گرافیکی شدت و جهت همبستگی‌ها را برجسته می‌کند و شناسایی روابط قوی یا متغیرهای تکراری را آسان‌تر می‌سازد.

❖ تحلیل پراکندگی (Dispersion Analysis)

تحلیل پراکندگی میزان پراکندگی یا تغییرپذیری داده‌ها را اندازه‌گیری می‌کند. این تحلیل نمایشی از نوسانات بازار یا تغییرات قیمت ارائه می‌دهد.

کاربرد

- ارزیابی نوسانات: شناسایی دوره‌های بی‌ثباتی در بازار.

- مدیریت ریسک: درک محدوده نتایج احتمالی.

❖ تحلیل مقایسه‌ای (Comparative Analysis)

تحلیل مقایسه‌ای توزیع‌ها و روندهای متغیرهای کلیدی (مانند Open, Close) را در میان سهام مختلف یا دوره‌های زمانی مقایسه می‌کند. با این تحلیل، شباهت‌ها، تفاوت‌ها و فرصت‌های سرمایه‌گذاری شناسایی شدند.

کاربرد

- معیارسازی: مقایسه سهام مختلف.
- شناسایی روندها: شناسایی تفاوت‌های خاص در متغیرها.

❖ تحلیل چندهم‌خطی (Multicollinearity Analysis)

چندهم‌خطی زمانی رخ می‌دهد که متغیرهای مستقل به شدت با یکدیگر همبسته باشند. این مسئله می‌تواند مدل‌های رگرسیونی را بی‌ثبات کند.

ابزارها

۱. عامل تورم واریانس (VIF): شدت چندهم‌خطی را اندازه‌گیری می‌کند.
۲. ماتریس همبستگی: روابط قوی بین متغیرهای مستقل را شناسایی می‌کند.

اهمیت

- شناسایی متغیرهای تکراری.
- بهبود دقت و پایداری مدل‌ها.

❖ تحلیل رگرسیون آماری (Statistical Regression Analysis)

رگرسیون آماری برای مدل‌سازی روابط بین متغیرهای کلیدی به کار رفت:

۱. رگرسیون ۲ بعدی: روابط بین جفت متغیرها بررسی شد.
۲. رگرسیون ۳ بعدی: اثر ترکیبی Open و High بر Close مدل‌سازی و در قالب یک صفحه سه‌بعدی نمایش داده شد.

نتیجه کلیدی

- مدل رگرسیون مقدار Close را بر اساس Open و High پیش‌بینی کرد. صفحه رگرسیون سه‌بعدی رابطه قوی خطی بین این متغیرها را برجسته کرد.

کاربردها

- بینش‌های پیش‌بینی‌کننده درباره قیمت سهام.
- شناسایی شدت وابستگی متغیرها.

جمع‌بندی

تحلیل آماری دیدگاه‌های ضروری درباره داده‌های بازار بورس ارائه داد، روابط کلیدی، روندها و رفتار داده‌ها را آشکار کرد. این نتایج پایه‌ای برای تحلیل‌های تک‌بعدی، دوجانبی و سه‌بعدی و همچنین تحلیل سری‌های زمانی در بخش‌های بعدی هستند.

۴.۲ تحلیل تک‌بعدی (Univariate Analysis)

در این بخش، تحلیل یک‌بعدی داده‌های مالی بورس انجام شد تا ویژگی‌ها و توزیع‌های تک‌متغیره داده‌ها بررسی شوند. از نمودارهای مختلف برای تحلیل استفاده شد، که شامل هیستوگرام، جعبه‌ای، ویولن، اسریپ، دایره‌ای، میله‌ای و رگ هستند. تمام نتایج این تحلیل‌ها در فایل `{ETF_name}_EDA_Statistical_analysis` پیاده‌سازی و نتایج آن ارائه شده است.

نمودارهای استفاده شده:

- **هیستوگرام (Histogram):** کاربرد: نمایش توزیع داده‌ها و شناسایی مقادیر پرت.
- **نمودار جعبه‌ای (Box Plot):** کاربرد: نمایش توزیع داده‌ها، شناسایی مقادیر پرت و پراکندگی.
- **نمودار ویولن (Violin Plot):** کاربرد: نمایش دقیق‌تر توزیع داده‌ها با ترکیب `Density Plot` و `Boxplot`.
- **نمودار اسریپ (Strip Plot):** کاربرد: نمایش پراکندگی داده‌ها و شناسایی نقاط پرت.
- **نمودار دایره‌ای (Pie Chart):** کاربرد: نمایش توزیع نسبی داده‌ها به صورت درصدی.
- **نمودار میله‌ای (Bar Chart):** کاربرد: مقایسه مقادیر گروهی یا دسته‌ای داده‌ها.
- **نمودار رگ (Rug Plot):** کاربرد: نمایش توزیع داده‌ها به صورت خطی و شناسایی تراکم مشاهدات.

نتیجه‌گیری

این تحلیل‌ها به ما کمک کردند تا توزیع و ویژگی‌های اصلی داده‌های بورس را شناسایی کرده و برای تحلیل‌های پیچیده‌تر در مراحل بعدی آماده شویم.

۴.۳ تحلیل دوبعدی (Bivariate Analysis)

در این بخش، تحلیل دوبعدی بین ویژگی‌های مختلف داده انجام شده است تا روابط و الگوهای موجود بین متغیرها مشخص شود. این تحلیل‌ها شامل ترسیم نمودارهای پراکندگی، بررسی همبستگی، مدل‌سازی رگرسیون، و تحلیل توزیع‌های دوبعدی است. هدف از این تحلیل‌ها شناسایی روابط معنادار و رفتار داده‌ها در مقایسه با متغیر "Volume" و سایر ویژگی‌های انتخاب شده است. تمام نتایج این تحلیل‌ها در فایل {ETF_name}_EDA_Statistical_analysis پیاده‌سازی و نتایج آن ارائه شده است.

• نمودار پراکندگی (Scatter Plot)

برای بررسی رابطه بین حجم معاملات "Volume" و سایر ویژگی‌ها، نمودارهای پراکندگی برای هر ویژگی ترسیم شد. این نمودارها نشان می‌دهند که داده‌ها در فضای دوبعدی چگونه توزیع شده‌اند و آیا الگوهای خاصی بین متغیرها وجود دارد یا خیر.

• نمودار رگرسیون (Regression Plot)

برای تحلیل دقیق‌تر روابط، نمودارهای رگرسیون برای هر جفت متغیر "Volume" و ویژگی‌های دیگر رسم شد. این نمودارها شامل خط رگرسیون قرمز رنگ هستند که روند کلی رابطه را نمایش می‌دهد.

• هیتمپ همبستگی (Correlation Heatmap)

ماتریس همبستگی بین متغیرها محاسبه و به صورت هیتمپ ترسیم شد.

- این ماتریس ضریب همبستگی بین متغیرها را نشان می‌دهد (بین -۱ و ۱).
- رنگ‌های هیتمپ تغییرات همبستگی را به صورت بصری برجسته می‌کنند، که به شناسایی روابط قوی یا ضعیف کمک می‌کند.

• نمودار توزیع دوبعدی (2D KDE Plot)

برای تحلیل تراکم داده‌ها، توزیع دوبعدی بین "Volume" و ویژگی‌های دیگر با استفاده از نمودارهای KDE ترسیم شد.

- این نمودارها تراکم نقاط داده در فضای دوبعدی را نشان می‌دهند.
- رنگ‌های مختلف شدت تراکم را نمایش می‌دهند، که نقاط پرتراکم و کم‌تراکم را تفکیک می‌کند.

• تحلیل دسته‌بندی (Categorical Analysis)

تحلیل دوبعدی برای بررسی روابط بین دسته‌بندی‌های خاص و حجم معاملات انجام شد.

- نمودار حرارتی (Heatmap): حجم میانگین معاملات بر اساس دسته‌بندی‌های مختلف "Open" و "Close" نمایش داده شد.
- نمودار نوار (Bar Plot): میانگین حجم معاملات برای دسته‌های برتر "Open" محاسبه و به صورت نمودار ستونی نمایش داده شد.
- نمودار دایره (Pie Chart): درصد دسته‌های مختلف "Open" برای ۱۰ دسته برتر به تصویر کشیده شد.

• نمودارهای جعبه‌ای و ویولن (Box Plot & Violin Plot)

برای بررسی توزیع حجم معاملات در دسته‌های مختلف، نمودارهای جعبه‌ای و ویولن ترسیم شدند.

- این نمودارها محدوده داده‌ها، میانه، و نقاط پرت هر دسته را نمایش می‌دهند.
- نمودار ویولن توزیع داده‌ها در هر دسته را به صورت دقیق‌تری نشان می‌دهد.

• نمودار نواری دسته‌های برتر (Strip Plot):

برای نمایش نقاط داده مربوط به دسته‌های برتر، از نمودار Strip استفاده شد.

- این نمودار، داده‌های خام را به صورت نقاط پراکنده نمایش داد.
- از دسته‌بندی‌های محدود (مثلاً ۱۵ دسته برتر) برای کاهش پیچیدگی استفاده شد.

این تحلیل‌ها به شناسایی روابط کلیدی و ارائه دیدگاه جامع‌تری از داده‌ها کمک کردند و مبنایی برای تصمیم‌گیری‌های بعدی فراهم ساختند.

نتایج:

- همبستگی قوی بین Open و Close: در هر سه ETF مشاهده شد.
- ارتباط ضعیف بین Volume و قیمت‌ها: به‌ویژه در ETF های VT و QQQ.
- GLD: نشان داد که حجم معاملات تأثیر کمتری بر قیمت طلا دارد.

4.4 تحلیل سه‌بعدی (3D Analysis)

تحلیل سه‌بعدی یکی از روش‌های بصری و تحلیلی قدرتمند برای درک روابط پیچیده میان چندین متغیر است. در این پروژه، این نوع تحلیل به ما امکان می‌دهد تا ارتباط میان متغیرهای کلیدی ETF ها مانند قیمت باز (Open)، قیمت بسته (Close)، بیشترین قیمت (High)، کمترین قیمت (Low)، و حجم معاملات (Volume) را در یک فضای سه‌بعدی بررسی کنیم.

ETF ها به دلیل ترکیب چندین متغیر مؤثر و تأثیرپذیری بالا از شرایط بازار، نیازمند تحلیل‌هایی هستند که بتوانند این پیچیدگی را نشان دهند. درک روابط سه‌بعدی به ما کمک می‌کند تا الگوها، همبستگی‌ها، و نقاط بحرانی را در بین متغیرها کشف کنیم و به بینشی عمیق‌تر درباره رفتار بازار دست یابیم.

نمودارهای کتابخانه Matplotlib:

- ۱) نمودار 3D Surface Plot:
- ۲) نمودار 3D Bar Plot:
- ۳) نمودار 3D Triangular Surface Plot:
- ۴) نمودار 3D Streamlines Plot:

نمودارهای کتابخانه Plotly:

- ۱) نمودار Streamtube:
- ۲) نمودار 3D Heatmap:
- ۳) نمودار Parallel Coordinates Plot:
- ۴) نمودار Rendering:

نتایج:

- در ETF VT: رفتار قیمت‌ها و حجم معاملات نسبتاً متعادل بود.
- در ETF GLD: قیمت‌ها مستقل از حجم معاملات رفتار می‌کردند.
- در ETF QQQ: نوسانات بالا و ارتباط نزدیک‌تر بین قیمت‌ها و حجم مشاهده شد.

۴.۵ تحلیل سری زمانی (Time Series Analysis)

تحلیل سری زمانی یکی از ابزارهای کلیدی در بررسی رفتار داده‌های مالی است که به ما امکان می‌دهد تغییرات داده‌ها را در طول زمان درک کنیم و روابط پنهان میان متغیرها را آشکار کنیم. این روش به‌ویژه در تحلیل **ETFها** که یکی از ابزارهای محبوب سرمایه‌گذاری در بازارهای مالی هستند، اهمیت زیادی دارد.

ETFها به دلیل ماهیت دینامیک خود، متغیرهای متعددی از جمله قیمت باز (Open)، قیمت بسته (Close)، بیشترین قیمت (High)، کمترین قیمت (Low)، و حجم معاملات (Volume) را در بر می‌گیرند که همگی به‌شدت تحت تأثیر زمان و شرایط بازار قرار دارند. تحلیل سری زمانی به ما کمک می‌کند تا روندها، الگوها، و رفتار این داده‌ها را در بازه‌های زمانی مختلف شناسایی کرده و تصمیم‌گیری‌های بهتری در زمینه سرمایه‌گذاری انجام دهیم.

انواع آنالیزها:

- (۱) Trend Analysis
- (۲) Seasonality Analysis
- (۳) Lagged Correlation Analysis
- (۴) Cumulative Analysis
- (۵) Moving Average Analysis
- (۶) Change point detection

نتایج:

- VT: روندی پایدارتر با نوسانات محدودتر داشت.
- GLD: تغییرات آرام‌تر و مستقل‌تر از عوامل خارجی.
- QQQ: نوسانات بیشتر، نشان‌دهنده رفتار پویاتر سهام فناوری.

۵ خوشه‌بندی

۵.۱ مقدمه‌ای بر خوشه‌بندی

خوشه‌بندی یکی از روش‌های یادگیری ماشین بدون نظارت^۱ است که برای گروه‌بندی داده‌ها بر اساس شباهت‌ها یا الگوهای موجود در آن‌ها استفاده می‌شود. در این پروژه، هدف از خوشه‌بندی، شناسایی الگوهای رفتاری مختلف در ETFها و بررسی تفاوت‌های کلیدی بین آن‌ها بود. از الگوریتم K-Means Clustering برای خوشه‌بندی استفاده شد.

۵.۲ روش خوشه‌بندی

الگوریتم K-Means

الگوریتم **K-Means** یکی از محبوب‌ترین روش‌های خوشه‌بندی است که به دلیل سادگی و کارایی در بسیاری از مسائل مورد استفاده قرار می‌گیرد. این الگوریتم داده‌ها را به تعداد مشخصی از خوشه‌ها (K) تقسیم می‌کند و تلاش می‌کند داده‌های هر خوشه را به گونه‌ای گروه‌بندی کند که شباهت درون خوشه‌ای حداکثر و تفاوت بین خوشه‌ها (O) حداقل شود.

مراحل الگوریتم:

این الگوریتم داده‌ها را به K خوشه تقسیم می‌کند، به گونه‌ای که داده‌های داخل هر خوشه شباهت بیشتری به مرکز آن خوشه داشته باشند. مراحل اصلی این الگوریتم عبارت‌اند از:

۱. انتخاب تعداد خوشه‌ها (K).
۲. مقداردهی اولیه مراکز خوشه‌ها.
۳. اختصاص هر نقطه داده به نزدیک‌ترین مرکز خوشه.
۴. به‌روزرسانی مراکز خوشه‌ها بر اساس میانگین نقاط داده در هر خوشه.
۵. تکرار مراحل ۳ و ۴ تا زمانی که مراکز خوشه‌ها ثابت شوند.

نقاط قوت K-Means

۱. **سادگی:** پیاده‌سازی و درک آن آسان است.
۲. **سرعت بالا:** به خصوص برای داده‌های بزرگ، در مقایسه با سایر الگوریتم‌های خوشه‌بندی کارآمدتر است.
۳. **انعطاف‌پذیری:** برای انواع مختلف داده‌ها قابل استفاده است.

محدودیت‌های K-Means

۱. **تعداد خوشه‌ها (K):**
 - تعداد خوشه‌ها باید از پیش مشخص شود، که ممکن است در برخی موارد دشوار باشد.
 - روش‌هایی مانند **Elbow** برای تعیین K استفاده می‌شود.

^۱ Unsupervised

^۲ Homogeneity

^۳ Heterogeneity

۲. حساسیت به مراکز اولیه:

- نتایج الگوریتم ممکن است بسته به انتخاب اولیه مراکز خوشه‌ها متفاوت باشد.

۳. حساسیت به داده‌های خارج از محدوده (Outliers):

- داده‌های پرت ممکن است بر نتایج خوشه‌بندی تأثیر زیادی بگذارند.

۴. شکل خوشه‌ها:

- K-Means به خوشه‌های کروی و با اندازه مشابه تمایل دارد و ممکن است در شناسایی خوشه‌های پیچیده‌تر ناکارآمد باشد.

کاربردهای K-Means

- تحلیل مشتریان: تقسیم‌بندی مشتریان بر اساس رفتار خرید.
- بخش‌بندی تصاویر: جداسازی بخش‌های مختلف تصویر.
- تشخیص الگو: شناسایی گروه‌های مشابه در داده‌ها.
- پردازش متن: خوشه‌بندی اسناد بر اساس شباهت‌های متنی.

۵.۳ تعیین تعداد خوشه‌ها

روش Elbow

روش **Elbow** یکی از روش‌های استاندارد برای تعیین تعداد بهینه خوشه‌ها در الگوریتم‌های خوشه‌بندی است. این روش بر مبنای تغییرات واریانس درون خوشه‌ای یا مجموع مربعات خطا (SSE) یا (WCSS) عمل می‌کند. هدف اصلی این روش شناسایی نقطه‌ای است که کاهش واریانس یا SSE با افزایش تعداد خوشه‌ها به حالت **کاهشی ناچیز** یا "پایداری" می‌رسد. این نقطه به شکل یک "آرنج" در نمودار دیده می‌شود و تعداد خوشه‌های متناظر با آن به عنوان تعداد بهینه خوشه‌ها انتخاب می‌شود.

نحوه کار روش Elbow:

۱. الگوریتم خوشه‌بندی برای تعداد مختلفی از خوشه‌ها اجرا می‌شود.
۲. برای هر تعداد خوشه، مقدار واریانس درون خوشه‌ای (WCSS) یا مجموع مربعات خطا (SSE) محاسبه می‌شود. (SSE) مجموع فاصله‌های مربعی نقاط از مراکز خوشه‌ها نشان است.
۳. نموداری با محور افقی تعداد خوشه‌ها و محور عمودی مقدار SSE رسم می‌شود.
۴. نقطه‌ای پیدا می‌شود که کاهش SSE پس از آن کمتر محسوس باشد. این نقطه که به شکل یک "آرنج" دیده می‌شود، نشان‌دهنده تعداد مناسب خوشه‌ها است.

دلیل کاهش SSE:

- با افزایش تعداد خوشه‌ها، هر خوشه کوچک‌تر می‌شود، بنابراین نقاط به مراکز خوشه‌های خود نزدیک‌تر می‌شوند. این امر باعث کاهش SSE می‌شود.
- اما پس از رسیدن به یک تعداد خاص، اضافه کردن خوشه‌های بیشتر تأثیر کمی بر کاهش SSE دارد و کاهش به حالت "پایداری" می‌رسد.

روش Elbow به طور گسترده‌ای برای انتخاب تعداد خوشه‌ها استفاده می‌شود و به دلیل سادگی و شهودی بودن، یکی از اولین انتخاب‌ها برای تحلیل خوشه‌بندی است.

۵.۴ اجرای خوشه‌بندی برای ETFها

متغیرهای مورد استفاده در خوشه‌بندی

برای خوشه‌بندی داده‌ها، متغیرهای زیر انتخاب شدند:

- قیمت باز شدن (Open)
- قیمت بسته شدن (Close)
- پایین‌ترین قیمت (Low)
- بالاترین قیمت (High)
- حجم معاملات (Volume)

۵.۵ بصری‌سازی نتایج خوشه‌بندی

نمودارهای دوبعدی

- نمایش داده‌ها با توجه به خوشه‌بندی روی محورهای مختلف:
 - Close و Open
 - Volume و Close
- رنگ‌بندی هر خوشه برای شناسایی الگوها.

نمودارهای سه‌بعدی

- استفاده از نمودارهای سه‌بعدی (3D Scatter) برای نمایش خوشه‌بندی بر اساس سه متغیر Open و Close و Volume.

۵.۶ تحلیل کلی خوشه‌بندی

تفاوت ETFها در خوشه‌بندی:

۱. VT: رفتار پایدار و خوشه‌بندی ساده‌تر.
۲. GLD: خوشه‌بندی بر اساس تغییرات ناگهانی در قیمت طلا.
۳. QQQ: خوشه‌بندی متنوع‌تر با بازتاب نوسانات بالاتر.

نکات کلیدی:

- ETFهایی با نوسانات پایین‌تر (مانند GLD و VT) خوشه‌بندی ساده‌تری داشتند.
- ETFهای پرنوسان (مانند QQQ) خوشه‌بندی پیچیده‌تر و رفتار پویاتری نشان دادند.

۶ مقایسه ETFها

در این فصل، نتایج تحلیل و خوشه‌بندی سه ETF منتخب (VT، GLD، و QQQ) با یکدیگر مقایسه می‌شوند. هدف از این مقایسه شناسایی تفاوت‌ها و شباهت‌های کلیدی میان این ETFها از نظر بازدهی، نوسانات، همبستگی، و روندهای قیمتی است. این مقایسه به ما کمک می‌کند تا الگوهای رفتاری این ETFها را بهتر درک کرده و بر اساس آن پیشنهادات سرمایه‌گذاری ارائه دهیم.

۶.۱ مقایسه بازدهی^۱ کل

محاسبه بازدهی کل

بازدهی کل هر ETF بر اساس تغییرات قیمت بسته شدن (Close) از اولین روز تا آخرین روز دوره زمانی محاسبه شد.

نتایج:

- VT: بازدهی پایدار اما متوسط را نشان داد که نمایانگر رفتار شاخص‌های جهانی است.
- GLD: بازدهی پایین‌تر، اما ثابت، نشان‌دهنده نقش طلا به‌عنوان یک دارایی امن.
- QQQ: بیشترین بازدهی را داشت، اما با نوسانات بالاتر همراه بود، که نشان‌دهنده پویایی سهام فناوری است.

۶.۲ مقایسه نوسانات^۲

نوسانات کلی

برای هر ETF، نوسانات کلی قیمت‌ها (بر اساس انحراف استاندارد ستون Close) محاسبه و مقایسه شد.

نوسانات دسته‌ای

نوسانات قیمت بر اساس دسته‌بندی Close_category برای هر ETF بررسی شد.

نوسانات زمانی

نوسانات ۳۰ روزه (Rolling Volatility) برای هر ETF محاسبه و مقایسه شد.

نتایج:

- VT: نوسانات کمتر و رفتار پایدارتر، که نمایانگر عملکرد یکنواخت شاخص‌های جهانی است.
- GLD: کمترین نوسانات، که نشان‌دهنده ثبات بازار طلا است.
- QQQ: بیشترین نوسانات، به دلیل ماهیت پویا و حساسیت بالای سهام فناوری.

¹ Total Returns

² Volatility

۶.۳ مقایسه روندهای قیمتی^۱

روندهای قیمتی در طول زمان

قیمت بسته شدن (Close) برای هر ETF در بازه زمانی بررسی و مقایسه شد:

- VT: روندی یکنواخت با رشد تدریجی.
- GLD: تغییرات جزئی در بازه‌های زمانی مختلف، نشان‌دهنده نقش طلا به‌عنوان یک دارایی محافظ.
- QQQ: رشد سریع‌تر با نوسانات بالاتر.

رفتار در بحران‌های اقتصادی

تحلیل روندهای قیمتی نشان داد که GLD در زمان بحران‌های اقتصادی (مانند سقوط بازارها) رفتار پایدارتری داشته است، در حالی که VT و QQQ نوسانات بیشتری را تجربه کرده‌اند.

۶.۴ مقایسه همبستگی^۲

همبستگی میان ETF ها

ماتریس همبستگی برای ستون‌های Close هر ETF محاسبه شد.

نتایج:

- VT و QQQ: همبستگی مثبت قوی داشتند، که نشان‌دهنده تأثیرپذیری از بازارهای سهام جهانی است.
- GLD و سایر ETF ها: همبستگی کمتری داشت، که نشان‌دهنده استقلال طلا از بازارهای سهام است.

۶.۵ تحلیل خوشه‌بندی

مقایسه خوشه‌ها

خوشه‌بندی داده‌ها با الگوریتم K-Means تفاوت‌های کلیدی در رفتار ETF ها را نشان داد:

- VT: خوشه‌ها نمایانگر رفتار پایدار بازارهای جهانی.
- GLD: خوشه‌بندی ساده‌تر با تمرکز بر دوره‌های ثبات و تغییرات جزئی.
- QQQ: خوشه‌ها بازتاب‌دهنده نوسانات بالاتر و تنوع رفتار قیمت‌ها.

تحلیل تفاوت خوشه‌ها

GLD بیشتر به ثبات در شرایط مختلف اشاره داشت.

- QQQ تنوع بیشتری را در رفتار خوشه‌ها نشان داد.

¹ Price Trends

² Correlation

- VT بین ثبات و تغییرات تدریجی تقسیم شد.

۶.۶ خلاصه مقایسه

ویژگی	VT	GLD	QQQ
بازدهی کل	متوسط	کم	بالا
نوسانات	کم	بسیار کم	بالا
همبستگی	با QQQ بالا	کم با سایرین	با VT بالا
رفتار کلی	پایدار و یکنواخت	ثبات در شرایط بحرانی	پویا و پرنوسان

۶.۷ نتیجه‌گیری

۱. ETF پایدارترین GLD: به دلیل ثبات قیمتی و نوسانات کم، برای سرمایه‌گذاران محافظه‌کار یا در زمان بحران اقتصادی مناسب است.
۲. ETF پرنوسان‌ترین QQQ: به دلیل نوسانات بالا و بازدهی بالقوه زیاد، برای سرمایه‌گذاران ریسک‌پذیر جذاب است.
۳. ETF متعادل VT: به دلیل رفتار پایدار و رشد تدریجی، برای سرمایه‌گذارانی که به دنبال تعادل میان ریسک و بازدهی هستند، مناسب است.

