

به نام خدا



دانشکده مهندسی کامپیوتر

نام درس: علوم داده

نام استاد: دکتر نادری

پروژه تحلیل اکتشافی داده‌ها بر روی مجموعه داده‌های ETF

اعضای گروه:

نیوشا یقینی، ۹۸۵۲۲۳۴۶

غزل عربعلی، ۹۷۵۲۱۳۹۶

تاریخ: آذر/۱۴۰۳

فهرست مطالب

فصل ۱. مقدمه	
۱.۱. هدف پروژه	
۱.۲. معرفی ETFها و اهمیت آنها در بازار مالی	
۱.۳. ساختار گزارش	
فصل ۲. شناخت داده‌ها	
۲.۱. منبع داده‌ها	
۲.۲. ساختار داده‌ها	
۲.۳. دسته بندی ETFها	
فصل ۳. پیش پردازش داده‌ها	
۳.۱. پاک سازی داده‌ها (حذف ستون‌های نامربوط، اصلاح نوع داده‌ها، و حذف مقادیر خالی)	
۳.۲. شناسایی و حذف نقاط پرت	
۳.۳. دسته بندی داده‌ها	
فصل ۴. تحلیل داده‌ها	
۴.۱. تحلیل آماری	
۴.۲. تحلیل تک بعدی	
۴.۳. تحلیل دوبعدی	
۴.۴. تحلیل سه بعدی	
۴.۵. تحلیل سری زمانی	
فصل ۵. خوشه بندی	
۵.۱. مقدمه ای بر خوشه بندی	
۵.۲. روش خوشه بندی	
۵.۳. تعیین تعداد خوشه‌ها	
۵.۴. اجرای خوشه بندی بر روی داده‌های ETF	
۵.۵. نتایج خوشه بندی و بصری سازی آن	
۵.۶. تحلیل نتایج خوشه بندی	
فصل ۶. مقایسه ETFها	
۶.۱. مقایسه بازدهی کل	
۶.۲. مقایسه نوسانات	
۶.۳. مقایسه روندهای قیمتی	

۶,۴	مقایسه همبستگی
۶,۵	تحلیل خوشه‌بندی
۶,۶	نتیجه‌گیری

۱ مقدمه

در دنیای امروز، صندوق‌های سرمایه‌گذاری قابل معامله (ETF) به یکی از ابزارهای اصلی سرمایه‌گذاری در بازارهای مالی تبدیل شده‌اند. این ابزارها به سرمایه‌گذاران این امکان را می‌دهند تا با هزینه کمتر، تنوع بیشتری در دارایی‌های خود ایجاد کنند و در عین حال از مزایای نقدشوندگی بالا و امکان معامله در طول روز بهره‌مند شوند.

این پروژه به تحلیل و مقایسه رفتار سه نوع مختلف از ETFها پرداخته است. این ETFها شامل **GLD**^۲ و **QQQ**^۳ می‌باشند.

در این گزارش، ویژگی‌های این سه ETF از جنبه‌های مختلفی مانند بازدهی، نوسانات و روندهای قیمتی بررسی خواهد شد. برای تحلیل این داده‌ها، از **تحلیل اکتشافی داده‌ها (EDA)** استفاده شده است که به شناسایی الگوهای نهفته در داده‌ها کمک می‌کند و رفتار هر ETF را به دقت بررسی می‌کند.

علاوه بر استفاده از روش‌های استاندارد برای تحلیل‌های مختلف مانند پاکسازی داده‌ها، تحلیل‌های آماری، خوشه‌بندی و دیگر موارد، در برخی مراحل از **روش‌های خلاقانه و ابتکاری** نیز استفاده شده است. به عنوان مثال، در بخش حذف **outlier**ها، یک روش ابتکاری برای شناسایی و حذف داده‌های غیرعادی معرفی شده که به بهبود دقت نتایج تحلیل کمک می‌کند.

هدف این پروژه تحلیل دقیق عملکرد این ETFها و شناسایی تفاوت‌ها و شباهت‌ها در رفتار آنها است. بر اساس این تحلیل‌ها، پیشنهادهایی برای سرمایه‌گذاری به خوانندگان و سرمایه‌گذاران ارائه خواهد شد.

۱.۱ هدف پروژه

هدف این پروژه، **تحلیل و مقایسه رفتار سه نوع مختلف از ETFها** است. این پروژه با هدف بررسی بازدهی، نوسانات و روندهای قیمتی سه ETF منتخب انجام شده است که عبارتند از:

- **VT**: نماینده شاخص بازارهای جهانی.
- **GLD**: نماینده بازار کالاها با تمرکز بر طلا.
- **QQQ**: نماینده سهام فناوری در شاخص Nasdaq-100.

اهداف این پروژه عبارتند از:

۱. **تحلیل داده‌ها**: بررسی ویژگی‌های هر ETF از جنبه‌های مختلف.
۲. **مقایسه ETFها**: شناسایی تفاوت‌ها و شباهت‌ها در عملکرد این سه ETF.
۳. **ارائه توصیه‌های سرمایه‌گذاری**: بر اساس نتایج تحلیل‌ها، ارائه پیشنهادات برای سرمایه‌گذاران.

^۱ Exchange-Traded Fund

^۲ Vanguard Total World Stock

^۳ SPDR Gold Shares

^۴ Invesco QQQ Trust

۱.۲ معرفی ETFها و اهمیت آنها در بازار مالی

ETFها نوعی از صندوقهای سرمایه‌گذاری هستند که در بورس اوراق بهادار معامله می‌شوند. به عبارت دیگر، آنها مشابه سهام هستند، اما به جای نمایندگی یک شرکت خاص، شامل مجموعه‌ای از دارایی‌ها مانند سهام، اوراق قرضه، کالاها یا سایر انواع دارایی‌ها می‌باشند.

ETFها به سرمایه‌گذاران این امکان را می‌دهند که با خرید یک واحد از صندوق، به طور همزمان در مجموعه‌ای از دارایی‌ها سرمایه‌گذاری کنند. این ویژگی باعث می‌شود که **ETF**ها به عنوان ابزاری با تنوع بالا و ریسک کمتری نسبت به سرمایه‌گذاری در یک دارایی خاص شناخته شوند. علاوه بر این، **ETF**ها مزایای متعددی دارند که آن‌ها را به ابزاری محبوب در بازارهای مالی تبدیل کرده است:

۱. **تنوع بالا** **ETF**ها: به سرمایه‌گذاران امکان می‌دهند با خرید یک واحد، در یک مجموعه متنوع از دارایی‌ها سرمایه‌گذاری کنند.
۲. **کاهش هزینه**: مدیریت **ETF**ها معمولاً هزینه کمتری نسبت به صندوقهای سرمایه‌گذاری سنتی دارد.
۳. **نقدشوندگی بالا** **ETF**ها: در بازارهای مالی به راحتی قابل خرید و فروش هستند.
۴. **انعطاف‌پذیری** **ETF**ها: می‌توانند شاخص‌ها، کالاها یا صنایع خاص را دنبال کنند.

علت انتخاب این **ETF**ها:

در این پروژه، سه **ETF** منتخب برای تحلیل و مقایسه انتخاب شده‌اند که هرکدام نماینده بخش خاصی از بازار مالی هستند. انتخاب این **ETF**ها به دلایل زیر انجام شده است:

- **VT**: این **ETF** نماینده شاخص بازارهای جهانی است و عملکرد کلی بازارهای سهام را در سطح جهانی منعکس می‌کند. انتخاب این **ETF** به ما این امکان را می‌دهد که عملکرد کلی بازارهای جهانی را در نظر بگیریم.
- **GLD**: این **ETF** نماینده بازار کالاها است و به طور خاص به طلا متمرکز است. رفتار مستقل از سهام و تأثیرگذاری آن بر اساس قیمت طلا باعث می‌شود که این **ETF** برای تحلیل رفتار بازار کالاها جذاب باشد.
- **QQQ**: این **ETF** نماینده سهام شرکت‌های فناوری در شاخص Nasdaq-100 است. به دلیل نوسانات و رشد بالای این بخش از بازار، این **ETF** به ما کمک می‌کند تا رفتار بخش فناوری را بهتر درک کنیم.

تحلیل این سه **ETF** به ما این امکان را می‌دهد که رفتار بازار را در دسته‌های مختلف (شاخص‌ها، کالاها و فناوری) بهتر درک کنیم و تأثیرات متقابل آن‌ها را در شرایط مختلف بازار مورد بررسی قرار دهیم.

۱.۳ ساختار گزارش

ساختار گزارش:

این گزارش شامل چندین بخش اصلی است که به تحلیل و مقایسه سه ETF منتخب پرداخته و نتایج مختلف را ارائه می‌دهند. ساختار گزارش به شرح زیر است:

۱. **مقدمه:** در این بخش، به اهمیت و کاربرد ETFها در بازار مالی پرداخته شده و هدف پروژه توضیح داده شده است.
۲. **معرفی داده‌ها:** در این بخش، منبع داده‌ها، ساختار آن‌ها و توضیحاتی در مورد هر یک از ETFها داده شده است.
۳. **پیش‌پردازش داده‌ها:** در این بخش، روش‌های استفاده‌شده برای پاکسازی و آماده‌سازی داده‌ها برای تحلیل توضیح داده می‌شود.
۴. **تحلیل داده‌ها:** شامل تحلیل‌های مختلف از جمله تحلیل تک‌بعدی، دوبعدی، سه‌بعدی و تحلیل سری زمانی است. این تحلیل‌ها در نوت‌بوک‌های جداگانه انجام شده‌اند و نتایج هر کدام به‌طور دقیق و واضح ارائه شده است.
۵. **خوشه‌بندی:** در این بخش، از روش‌های خوشه‌بندی برای شناسایی الگوها و گروه‌بندی ETFها استفاده شده است. نتایج خوشه‌بندی به تفکیک در نوت‌بوک مربوطه آورده شده و تحلیل‌های مربوط به آن ارائه می‌شود.
۶. **مقایسه ETFها:** در این بخش، تفاوت‌ها و شباهت‌های عملکردی سه ETF منتخب مقایسه شده است.

تمامی نوت‌بوک‌های مربوط به تحلیل‌ها و نتایج در کنار گزارش تحویل داده خواهند شد. در هر نوت‌بوک، کدها، نتایج تحلیل‌ها و بصری‌سازی‌های مربوطه گنجانده شده و تحلیل‌های مختص به آن‌ها در زیر هر بخش آورده شده است.

کدهای پروژه علاوه بر اینکه در نوت‌بوک‌ها در گزارش گنجانده شده‌اند، از طریق **GitHub** نیز در دسترس هستند.

۲ معرفی داده‌ها

در این پروژه، داده‌ها از دیتاست **Huge Stock Market Dataset** موجود در وبسایت **Kaggle** استخراج شده است. این دیتاست یکی از معتبرترین منابع داده در زمینه بازارهای مالی است که به‌طور گسترده توسط تحلیل‌گران مالی مورد استفاده قرار می‌گیرد. تا کنون، این دیتاست بیش از **121,803** بار دانلود و **1.11** میلیون بار بازدید داشته است و به عنوان یکی از بهترین دیتاست‌های موجود در زمینه تحلیل‌های بازار سهام و ETF شناخته می‌شود.

دیتاست شامل اطلاعات تاریخی قیمت و حجم معاملات برای تمامی سهام و صندوق‌های سرمایه‌گذاری قابل معامله (ETF) در بازارهای مالی ایالات متحده است که در بورس‌های **NYSE**، **NASDAQ** و **NYSE MKT** معامله می‌شوند. این دیتاست تا تاریخ **11 نوامبر ۲۰۱۷** به‌روز رسانی شده است و به فرمت **CSV** ارائه شده است.

۲.۱ منبع داده‌ها

منبع اصلی داده‌های این پروژه، دیتاست **Huge Stock Market Dataset** موجود در سایت **Kaggle** است. این دیتاست شامل داده‌های روزانه قیمت و حجم معاملات برای سهام و ETFهای مختلف است. مشخصات اصلی این دیتاست به شرح زیر است:

- منبع: وبسایت Kaggle

<https://www.kaggle.com/datasets/borismarjanovic/price-volume-data-for-all-us-stocks-etfs>

- نوع داده‌ها: داده‌های روزانه قیمت باز شدن، بالاترین قیمت، پایین‌ترین قیمت، قیمت بسته‌شدن، و حجم معاملات.
- دوره زمانی: اطلاعات تاریخی چندین سال از بازارهای مالی.
- کاربرد: این داده‌ها می‌توانند برای تحلیل روندهای بازار، بررسی رفتار سهام یا ETFها، و ارزیابی نوسانات استفاده شوند.

این دیتاست در مجموع دارای **8539** فایل است که **1344** فایل از آن مربوط به داده‌های ETFها هستند. اندازه دیتاست تقریباً **809.02 MB** است و در مجموع شامل **2362** رکورد در هر فایل می‌باشد.

۲.۲ ساختار داده‌ها

داده‌های موجود در هر فایل دیتاست شامل ستون‌های مختلفی هستند که به شرح زیر است:

ستون	توضیحات
Date	تاریخ معامله (در فرمت YYYY-MM-DD)
Open	قیمت باز شدن روزانه
High	بالاترین قیمت ثبت‌شده در طول روز
Low	پایین‌ترین قیمت ثبت‌شده در طول روز
Close	قیمت بسته‌شدن روزانه
Volume	حجم کل معاملات انجام‌شده در طول روز

این ساختار برای تمام ETFها و سهام موجود در دیتاست مشابه است. تعداد رکوردها بستگی به تعداد روزهای معاملاتی دارد و معمولاً شامل داده‌های چندین ساله از بازارهای مالی ایالات متحده است.

۲.۳ دسته بندی ETFها

دیتاست ETFها در سایت Kaggle شامل گروه‌های مختلفی از داده‌ها است که به دسته‌بندی‌های مختلف تقسیم می‌شوند. این دسته‌بندی‌ها به شرح زیر است:

۱. **Index ETFs**: ETFهایی که نماینده شاخص‌های بازار هستند و شامل مجموعه‌ای از سهام در یک شاخص خاص می‌باشند. این دسته از ETFها برای تحلیل کلی بازار و روندهای عمومی بازار مناسب هستند.
۲. **Commodities ETFs**: ETFهایی که شاخص‌هایی از کالاها را دنبال می‌کنند. به عنوان مثال، ETFهایی که قیمت طلا، نفت یا دیگر کالاها را رصد می‌کنند.
۳. **Equity ETFs**: ETFهایی که شامل سهام شرکت‌ها در یک بخش خاص یا شاخص سهام هستند و به طور معمول برای تحلیل صنایع خاص یا سهام شرکت‌های برجسته استفاده می‌شوند.
۴. **Bond ETFs**: این ETFها نماینده اوراق قرضه هستند و برای تحلیل بازار بدهی مناسب می‌باشند.
۵. **Sector ETFs**: ETFهایی که مخصوص یک صنعت خاص مانند تکنولوژی، سلامت یا انرژی هستند.
۶. **Thematic ETFs**: ETFهایی که به موضوعات خاص مانند انرژی‌های تجدیدپذیر، رباتیک، یا بلاک چین می‌پردازند.

در این پروژه، سه ETF منتخب از این مجموعه داده انتخاب شدند که نماینده دسته‌های مختلف ETFها هستند. این ETFها عبارت‌اند از:

1. VT (Vanguard Total World Stock ETF)

- **دسته‌بندی Index ETF**
- **توضیح VT**: نماینده شاخص بازارهای جهانی است. این ETF شامل ترکیبی از سهام آمریکایی و بین‌المللی است و به عنوان یک شاخص جامع رفتار کلی بازار جهانی را نشان می‌دهد.
- **دلیل انتخاب**:
 - VT رفتار کل بازارهای جهانی را منعکس می‌کند.
 - تحلیل این ETF به شناسایی روندهای کلی در بازار سهام جهانی کمک می‌کند.

2. GLD (SPDR Gold Shares)

- **دسته‌بندی Commodities ETF**
- **توضیح GLD**: یکی از شناخته‌شده‌ترین ETFها در بازار کالاها است که قیمت طلا را دنبال می‌کند. طلا معمولاً به عنوان یک "پناهگاه امن" در شرایط نوسانات اقتصادی عمل می‌کند.
- **دلیل انتخاب**:
 - تحلیل GLD به بررسی رفتار مستقل کالاها در مقایسه با سهام و شاخص‌ها کمک می‌کند.
 - طلا به عنوان یک دارایی امن در زمان بحران‌های مالی، رفتار متفاوتی نسبت به دیگر دارایی‌ها دارد.

3. *QQQ (Invesco QQQ Trust)*

- دسته‌بندی **Equity ETF**
- توضیح **QQQ**: یکی از محبوب‌ترین ETFهای بازار است که سهام ۱۰۰ شرکت برتر فناوری در شاخص **Nasdaq** را شامل می‌شود. این ETF نشان‌دهنده رشد و نوآوری‌های صنعت فناوری است.
- دلیل انتخاب:
 - **QQQ** به دلیل نوسانات بالا و بازدهی بالقوه زیاد، برای مقایسه با ETFهای پایدارتر مانند **VT** و **GLD** مناسب است.
 - تحلیل **QQQ** به درک بهتر تأثیر فناوری در بازار کمک می‌کند.

نتیجه‌گیری:

دیتاست موجود در **Kaggle** شامل داده‌های متنوع از ETFها است که به دسته‌های مختلف بازار (شاخص‌ها، کالاها، سهام و ...) تعلق دارند. در این پروژه، با انتخاب سه ETF از دسته‌های مختلف شامل **Equity ETF**، **Commodities ETF**، **Index ETF**، به تحلیل و مقایسه رفتار بازار از جنبه‌های مختلف پرداخته شده است. این انتخاب‌ها به ما کمک می‌کنند تا دیدگاه‌های جامعی از روندهای کلی بازار، بازار کالاها و بازار فناوری به دست آوریم.

۳ پیش‌پردازش داده‌ها

پیش‌پردازش داده‌ها یکی از مهم‌ترین مراحل در تحلیل داده‌ها است که به بهبود کیفیت، دقت، و تفسیر نتایج کمک می‌کند. این فصل شامل تمام مراحل پیش‌پردازش انجام‌شده در فایل `{ETF_name}_EDA_PreProcess.ipynb` است که همراه با توضیحات دقیق و تحلیل‌های گرافیکی برای هر مرحله ارائه شده است. از میان این مراحل، دو روش جدید برای حذف داده‌های پرت به‌عنوان نوآوری‌های اصلی ما معرفی شده‌اند:

1. **Density-Based Method**
2. **Adaptive Skewness-Based Outlier Filtering (ASBOF)**

این گزارش به تفصیل مراحل پیش‌پردازش شامل پاک‌سازی داده‌ها^۱، حذف داده‌های پرت^۲، نرمال‌سازی^۳، و دسته‌بندی^۴ را پوشش می‌دهد.

۳.۱ پاک‌سازی داده‌ها

۱. **حذف ستون‌های غیرضروری:** ستون `OpenInt` به دلیل داشتن مقادیر صفر در تمام سطرها حذف شد.
۲. **فرمت‌بندی تاریخ‌ها:** ستون `Date` به فرمت `datetime` تبدیل شد تا دسترسی و استفاده از داده‌ها آسان‌تر شود.
۳. **بررسی مقادیر Null:** داده‌های ما هیچ مقدار `Null` نداشتند، بنابراین نیازی به اقدامات اضافی نبود.

۳.۲ شناسایی و حذف نقاط پرت

داده‌های پرت می‌توانند به‌شدت تحلیل‌ها را تحت تأثیر قرار دهند. با استفاده از نمودارهای **Boxplot**، داده‌های پرت را شناسایی کردیم و برای حذف کردن آنها از روش‌های زیر استفاده شد و نتایج مقایسه شدند، همچنین نتایج در فایل‌های مربوطه ذخیره شدند:

❖ روش IQR

❖ روش Percentiles

❖ روش Z-Score

❖ روش Density-Based – نوآوری اول

توضیحات گام به گام الگوریتم:

۱. **محاسبه هیستوگرام:** برای هر ستون از داده‌ها (مثل `Open`, `Low`, `High`, `Close`, `Volume`)، هیستوگرام با `bin ۲۰` محاسبه می‌شود. هیستوگرام نشان‌دهنده توزیع فراوانی داده‌ها در فواصل مختلف است.
۲. **محاسبه چولگی (Skewness):** چولگی، معیاری است برای نشان دادن نحوه انحراف توزیع داده‌ها از یک توزیع نرمال. اگر چولگی کمتر از ۱ باشد، توزیع به‌صورت تقریبی نرمال است. این مقدار برای هر ستون محاسبه می‌شود و به تصمیم‌گیری برای تعیین درصد مورد استفاده در مرحله بعد کمک می‌کند.

¹ Preprocessing

² Contributions

³ Data Cleaning

⁴ Outliers

⁵ Normalization

⁶ Categorization

۳. **تعیین درصد بر اساس چولگی:** بر اساس مقدار چولگی برای هر ستون، یک درصد مشخص از هیستوگرام انتخاب می‌شود که نشان‌دهنده درصدی از داده‌هاست که باید در فرآیند فیلترینگ استفاده شود. این درصد می‌تواند از ۵۰ درصد تا ۹۰ درصد تغییر کند.
۴. **محاسبه آستانه چگالی داینامیک:** پس از تعیین درصد، آستانه چگالی به عنوان ۸۰ درصد از صدک داده‌های هیستوگرام محاسبه می‌شود. این آستانه، خط مرزی است که داده‌های کم‌چگالی (که ممکن است نویز باشند) شناسایی می‌شوند.
۵. **شناسایی نواحی کم‌چگالی:** با استفاده از آستانه چگالی، بین‌هایی که دارای چگالی کمتر از آستانه هستند شناسایی می‌شوند. این نواحی به احتمال زیاد نقاط داده غیرمعتبر یا نویز هستند.
۶. **حذف داده‌ها از نواحی کم‌چگالی:** در نهایت، داده‌هایی که در نواحی کم‌چگالی قرار دارند، از دیتافریم حذف می‌شوند تا دیتای تمیزتری داشته باشیم.

۷. **خروجی و گزارش:** س از انجام فیلترینگ برای هر ستون، نتایج در یک فایل متنی ذخیره می‌شود که شامل موارد زیر است:

- مقدار چولگی هر ستون
- درصد مورد استفاده برای تعیین آستانه
- آستانه چگالی داینامیک
- شاخص‌های بین‌های کم‌چگالی
- رنج‌های کم‌چگالی
- شکل نهایی دیتافریم پس از فیلترینگ

این روش به‌ویژه برای شناسایی و حذف داده‌های غیرمعتبر یا نویز از داده‌های مالی یا سایر داده‌های زمان‌سری مفید است که می‌تواند بر کیفیت مدل‌های تحلیلی تأثیر منفی بگذارد.

عملکرد این روش بهتر از روش‌های سنتی بود و منجر به حذف داده‌های پرت بدون حذف بیش‌ازحد داده‌ها شد.

نتایج با نمودارها در بخش‌های مربوطه مشخص شده‌اند.

❖ روش Adaptive Skewness-Based Outlier Filtering (ASBOF) – نوآوری دوم

توضیحات گام به گام الگوریتم:

۱. **محاسبه چولگی (Skewness):** اولین قدم در این الگوریتم محاسبه چولگی برای هر ستون از داده‌ها است. چولگی معیاری است که نشان می‌دهد داده‌ها تا چه حد از یک توزیع نرمال منحرف شده‌اند. اگر چولگی زیاد باشد، یعنی داده‌ها به‌طور غیرمعمولی توزیع شده‌اند و احتمالاً نیاز به اصلاح دارند.
۲. **انتخاب آستانه ثابت یا دینامیک:**
 - اگر چولگی بیشتر از ۳ باشد، آستانه به‌طور خودکار و دینامیک تنظیم می‌شود تا داده‌هایی که در نواحی کم‌چگالی قرار دارند حذف شوند.
 - اگر چولگی کمتر از ۳ باشد، از آستانه ثابت استفاده می‌کنیم. این آستانه برای هر ستون بر اساس ۵ درصد و ۹۵ درصد صدک‌های داده‌ها تعیین می‌شود. بنابراین فقط داده‌هایی که در این محدوده قرار دارند نگه‌داشته می‌شوند.
۳. **تنظیم آستانه دینامیک:** وقتی چولگی ستون زیاد باشد، درصدی از داده‌ها به‌طور تدریجی حذف می‌شود. برای هر درصد، آستانه چگالی محاسبه می‌شود و سپس داده‌هایی که در نواحی کم‌چگالی قرار دارند، فیلتر می‌شوند. این فرآیند به‌طور تدریجی برای کاهش نویز در داده‌ها اعمال می‌شود.
۴. **بهینه‌سازی آستانه دینامیک:** در طول این فرآیند، اگر متوجه شویم که کاهش چولگی خیلی کند شده است، اندازه گام تغییر می‌کند تا فرآیند سریع‌تر پیش برود. این تنظیم خودکار اندازه گام باعث می‌شود که الگوریتم به‌طور بهینه‌تر عمل کند.

۵. **اعمال فیلترینگ:** پس از تعیین آستانه مناسب، داده‌های نهایی برای هر ستون فیلتر می‌شوند و فقط داده‌هایی که به‌طور واقعی نویز هستند حذف می‌شوند. در نهایت، این داده‌ها در یک فایل متنی ذخیره می‌شوند تا گزارشی دقیق از نتایج فیلترینگ برای هر ستون ارائه شود.
۶. **خلاصه نهایی:** بعد از انجام فیلترینگ برای تمامی ستون‌ها، یک خلاصه از تعداد داده‌های باقی‌مانده در هر ستون و شکل نهایی دیتافریم فیلترشده تهیه می‌شود.

مزایای این روش:

- **تنظیم خودکار آستانه:** با توجه به چولگی داده‌ها، آستانه‌ها به‌طور خودکار تنظیم می‌شوند تا بهترین فیلترینگ را برای داده‌هایی که توزیع نرمال ندارند، انجام دهد.
- **بهینه‌سازی خودکار:** اندازه گام به‌طور خودکار تنظیم می‌شود تا فرآیند فیلترینگ بهینه‌تر و سریع‌تر پیش برود.
- **کاهش از دست دادن داده‌ها:** این روش تنها داده‌هایی که واقعاً نویز هستند را حذف می‌کند و اطلاعات مفید را حفظ می‌کند.

نتیجه‌گیری:

الگوریتم **ASBOF** روشی هوشمندانه برای فیلتر کردن داده‌ها است که به‌ویژه در داده‌هایی با توزیع نامتعارف یا داده‌هایی که شامل نویز هستند، بسیار مفید است. استفاده از چولگی برای تنظیم آستانه‌ها و بهینه‌سازی دینامیک باعث می‌شود این روش دقت بالاتری در فیلتر کردن داده‌های غیرمعتبر داشته باشد.

این روش بهترین عملکرد را داشت و خروجی نهایی به‌صورت CSV ذخیره شد.

۳.۳ نرمال‌سازی داده‌ها

داده‌ها برای اطمینان از مقیاس‌بندی یکسان، نرمال‌سازی شدند.

- **اهمیت:**
 - بهبود عملکرد در الگوریتم‌های خوشه‌بندی و یادگیری ماشین.
 - حذف تأثیر مقیاس‌های مختلف در تحلیل داده‌ها.
- **نتیجه:** داده‌های نرمال‌شده در فایل CSV جداگانه ذخیره شدند.

۳.۴ دسته‌بندی داده‌ها

به دلیل تمایز زیاد داده‌ها، آن‌ها را دسته‌بندی کردیم. برای این کار از قوانین زیر استفاده شد:

۱. **Sturges' Rule:** تعداد bins را بر اساس $\log 2(n) + 1$ تعیین می‌کند.
 ۲. **Freedman-Diaconis Rule:** تعداد bins بر اساس IQR و اندازه داده تعیین شد.
 ۳. **Scott's Rule:** تعداد bins بر اساس انحراف معیار داده تعیین شد.
 ۴. **Rice Rule:** تعداد bins برابر $2 \times n^{3/5}$ محاسبه شد.
- **نتیجه:** از ترکیب نتایج **Scott** و **Freedman-Diaconis** استفاده شد، زیرا منجر به توزیع متعادل‌تر داده‌ها شد.

۳.۵ ذخیره سازی و بازیابی داده ها

- مشکل: هنگام ذخیره سازی داده های دسته بندی شده به صورت CSV، نوع داده ها از category به object تغییر کرد.
- راه حل ها:

۱. تبدیل ستون ها به category هنگام خواندن فایل.
۲. استفاده از فرمت های pickle یا parquet برای حفظ نوع داده.

نتیجه گیری:

این فصل پردازش شامل روش های استاندارد و پیشرفته برای پاک سازی و تحلیل داده ها بود. با معرفی دو روش جدید برای حذف داده های پرت و دسته بندی دقیق داده ها، توانستیم مجموعه داده ای تمیز و قابل اعتماد ایجاد کنیم که آماده استفاده در مراحل بعدی تحلیل است.

۴ تحلیل داده‌ها

۴.۱ تحلیل آماری

در این بخش، به تحلیل آماری مجموعه داده‌های مالی خود که شامل داده‌های بازار بورس است، پرداخته‌ایم. تحلیل آماری پایه‌ای برای درک ساختار داده‌ها و شناسایی الگوها یا ناهنجاری‌های معنادار است. ما چندین تحلیل آماری اساسی را برای شناسایی توزیع داده‌ها، روابط بین متغیرها و رفتار کلی بازار انجام داده‌ایم.

تمام نتایج و نمودارهای مرتبط با این بخش در فایل `{ETF_name}_EDA_Statistical_analysis` قرار داده شده‌اند. این تحلیل‌ها بر روی مجموعه داده پاکسازی‌شده‌ای انجام شده است که در فصل قبلی آماده‌سازی شده است، بنابراین هیچ داده‌ای با مقادیر گمشده یا خطاهای آشکار باقی نمانده است.

❖ آمار توصیفی

آمار توصیفی اولین گام در تحلیل آماری ما بود که برای خلاصه‌سازی و درک ویژگی‌های کلیدی مجموعه داده استفاده شد. برای هر ستون، معیارهای زیر محاسبه شد:

- **Count (تعداد)**
- **Mean (میانگین)**
- **Standard Deviation (انحراف معیار)**
- **Min و Max**
- **Quartiles (چارک‌ها)**

این آمارها یک نمای کلی از مجموعه داده فراهم کرده و به شناسایی ناهنجاری‌ها و درک گرایش مرکزی و پراکندگی داده‌ها کمک کردند. برای دیتاست اولیه، و دیتاست دسته‌بندی شده آن را اعمال کردیم.

❖ تحلیل نمودار Boxplot

برای ارزیابی تصویری توزیع داده‌ها و شناسایی مقادیر پرت احتمالی، نمودارهای **boxplot** برای متغیرهای کلیدی ترسیم شد. از آنجا که مجموعه داده از قبل پاکسازی شده بود، این مرحله عمدتاً تأیید کرد که مقادیر پرت شدیدی در داده‌ها وجود ندارد و توزیع داده‌ها به خوبی نمایش داده شد.

❖ تحلیل چولگی و کشیدگی (Skewness and Kurtosis Analysis)

- **چولگی (Skewness)** میزان عدم تقارن توزیع داده را اندازه‌گیری می‌کند. چولگی برابر با ۰ نشان‌دهنده توزیع کاملاً متقارن است، در حالی که چولگی مثبت یا منفی به معنای کشیدگی دم به سمت راست یا چپ است.

- **کشیدگی (Kurtosis)** میزان "دمدار بودن" توزیع داده را مشخص می‌کند. کشیدگی بالا نشان‌دهنده دم‌های سنگین‌تر و کشیدگی پایین نشان‌دهنده دم‌های سبک‌تر نسبت به توزیع نرمال است.

بررسی چولگی و کشیدگی به دلایل زیر اهمیت دارد:

۱. **ارزیابی نرمال بودن توزیع:** توزیع نرمال دارای چولگی نزدیک به ۰ و کشیدگی نزدیک به ۳ است.
۲. **انتخاب مدل:** بسیاری از مدل‌های آماری فرض نرمال بودن داده‌ها را دارند؛ انحراف از این فرض ممکن است نیاز به تبدیل داده‌ها یا استفاده از روش‌های جایگزین داشته باشد.
۳. **تحلیل ریسک:** در داده‌های مالی، چولگی و کشیدگی می‌توانند نشان‌دهنده وجود ریسک‌های افراطی یا فرصت‌های غیرمنتظره باشند.

❖ آزمون‌های فرضیه آماری (Statistical Hypothesis Testing)

در این بخش، آزمون‌های آماری زیر برای ارزیابی ویژگی‌های داده‌ها و بررسی فرضیه‌ها انجام شد:

آزمون Shapiro-Wilk

- **هدف:** بررسی اینکه آیا داده‌ها از توزیع نرمال پیروی می‌کنند.
- **کاربرد:** در ارزیابی پیش‌فرض‌های موردنیاز برای آزمون‌های پارامتری استفاده می‌شود.
- **خروجی:** مقدار p ؛ اگر کمتر از ۰,۰۵ باشد، فرض نرمال بودن رد می‌شود.

آزمون Kolmogorov-Smirnov

- **هدف:** مقایسه توزیع نمونه با یک توزیع مرجع (مثلاً توزیع نرمال).
- **کاربرد:** برای شناسایی تفاوت بین توزیع‌ها استفاده می‌شود.
- **خروجی:** مقدار p برای پذیرش یا رد فرضیه صفر.

آزمون T-Test

- **هدف:** مقایسه میانگین دو گروه برای تعیین اختلاف معنادار.
- **کاربرد:** مناسب برای مقایسه عملکرد دو سهم یا گروه.
- **انواع:** یک نمونه‌ای، دو نمونه‌ای، و جفتی.

آزمون ANOVA

- **هدف:** بررسی برابری میانگین‌های چند گروه.
- **کاربرد:** برای مقایسه گروه‌های متعدد در بازار بورس.
- **خروجی:** مقدار p و F-Statistic؛ مقادیر معنادار نشان‌دهنده تفاوت میانگین گروه‌ها است.

❖ تحلیل همبستگی (Correlation Analysis)

همبستگی Spearman

- هدف: اندازه‌گیری روابط یکنواخت (مانند روابط غیرخطی اما ترتیبی) بین متغیرها.
- کاربرد: مناسب برای داده‌هایی که رتبه‌بندی شده یا غیر پارامتری هستند.

همبستگی Pearson

- هدف: اندازه‌گیری روابط خطی بین متغیرها.
- کاربرد: معمولاً برای درک وابستگی خطی بین قیمت‌ها استفاده می‌شود.

مقایسه:

- **Pearson** بر خطی بودن تمرکز دارد، در حالی که **Spearman** روابط یکنواخت را شناسایی می‌کند.
- هر دو معیار دیدگاه‌های مکملی درباره قدرت و جهت روابط ارائه می‌دهند.

ماتریس همبستگی

ماتریس همبستگی، همبستگی جفتی بین تمام متغیرها را خلاصه می‌کند و نمای کاملی از وابستگی متغیرها ارائه می‌دهد.

نقشه حرارتی ماتریس همبستگی

برای بهبود خوانایی، ماتریس همبستگی با استفاده از نقشه حرارتی نمایش داده شد. این نمایش گرافیکی شدت و جهت همبستگی‌ها را برجسته می‌کند و شناسایی روابط قوی یا متغیرهای تکراری را آسان‌تر می‌سازد.

❖ تحلیل پراکندگی (Dispersion Analysis)

تحلیل پراکندگی میزان پراکندگی یا تغییرپذیری داده‌ها را اندازه‌گیری می‌کند. این تحلیل نمایشی از نوسانات بازار یا تغییرات قیمت ارائه می‌دهد.

کاربرد

- ارزیابی نوسانات: شناسایی دوره‌های بی‌ثباتی در بازار.
- مدیریت ریسک: درک محدوده نتایج احتمالی.

❖ تحلیل مقایسه‌ای (Comparative Analysis)

تحلیل مقایسه‌ای توزیع‌ها و روندهای متغیرهای کلیدی (مانند Open, Close) را در میان سهام مختلف یا دوره‌های زمانی مقایسه می‌کند. با این تحلیل، شباهت‌ها، تفاوت‌ها و فرصت‌های سرمایه‌گذاری شناسایی شدند.

کاربرد

- معیارسازی: مقایسه سهام مختلف.

- شناسایی روندها: شناسایی تفاوت‌های خاص در متغیرها.

❖ تحلیل چندهم‌خطی (Multicollinearity Analysis)

چندهم‌خطی زمانی رخ می‌دهد که متغیرهای مستقل به شدت با یکدیگر همبسته باشند. این مسئله می‌تواند مدل‌های رگرسیونی را بی‌ثبات کند.

اثرها

۱. عامل تورم واریانس (VIF): شدت چندهم‌خطی را اندازه‌گیری می‌کند.
۲. ماتریس همبستگی: روابط قوی بین متغیرهای مستقل را شناسایی می‌کند.

اهمیت

- شناسایی متغیرهای تکراری.
- بهبود دقت و پایداری مدل‌ها.

❖ تحلیل رگرسیون آماری (Statistical Regression Analysis)

رگرسیون آماری برای مدل‌سازی روابط بین متغیرهای کلیدی به کار رفت:

۱. رگرسیون ۲ بعدی: روابط بین جفت متغیرها بررسی شد.
۲. رگرسیون ۳ بعدی: اثر ترکیبی Open و High بر Close مدل‌سازی و در قالب یک صفحه سه‌بعدی نمایش داده شد.

نتیجه کلیدی

- مدل رگرسیون مقدار Close را بر اساس Open و High پیش‌بینی کرد. صفحه رگرسیون سه‌بعدی رابطه قوی خطی بین این متغیرها را برجسته کرد.

کاربردها

- پیش‌بینی ارزش‌های آینده در بازار بورس.
- شناسایی شدت وابستگی متغیرها.

جمع‌بندی

تحلیل آماری دیدگاه‌های ضروری درباره داده‌های بازار بورس ارائه داد، روابط کلیدی، روندها و رفتار داده‌ها را آشکار کرد. این نتایج پایه‌ای برای تحلیل‌های تک‌بعدی، دوطبقه و سه‌بعدی و همچنین تحلیل سری‌های زمانی در بخش‌های بعدی هستند.

۴.۲ تحلیل تک‌بعدی (Univariate Analysis)

در این بخش، تحلیل یک‌بعدی داده‌های مالی بورس انجام شد تا ویژگی‌ها و توزیع‌های تک‌متغیره داده‌ها بررسی شوند. تمام نتایج این تحلیل‌ها در فایل `{ETF_name}_EDA_1d.ipynb` پیاده‌سازی و نتایج آن ارائه شده است. از نمودارهای مختلف برای تحلیل استفاده شد، که شامل هیستوگرام، جعبه‌ای، ویولن، اسریپ، دایره‌ای، میله‌ای و رگ هستند.

نمودارهای استفاده‌شده:

- **هیستوگرام: (Histogram)**
کاربرد: نمایش توزیع داده‌ها و شناسایی مقادیر پرت.
- **نمودار جعبه‌ای: (Box Plot)**
کاربرد: نمایش توزیع داده‌ها، شناسایی مقادیر پرت و پراکندگی.
- **نمودار ویولن: (Violin Plot)**
کاربرد: نمایش دقیق‌تر توزیع داده‌ها با ترکیب **Boxplot** و **Density Plot**.
- **نمودار اسریپ: (Strip Plot)**
کاربرد: نمایش پراکندگی داده‌ها و شناسایی نقاط پرت.
- **نمودار دایره‌ای: (Pie Chart)**
کاربرد: نمایش توزیع نسبی داده‌ها به صورت درصدی.
- **نمودار میله‌ای: (Bar Chart)**
کاربرد: مقایسه مقادیر گروهی یا دسته‌ای داده‌ها.
- **نمودار رگ: (Rug Plot)**
کاربرد: نمایش توزیع داده‌ها به صورت خطی و شناسایی تراکم مشاهدات.

نتیجه‌گیری

این تحلیل‌ها به ما کمک کردند تا توزیع و ویژگی‌های اصلی داده‌های بورس را شناسایی کرده و برای تحلیل‌های پیچیده‌تر در مراحل بعدی آماده شویم.

۴.۳ تحلیل دوبعدی (Bivariate Analysis)

مقایسه متغیرها:

در این بخش، ارتباط میان متغیرهای کلیدی (مانند Open, Close, Volume) بررسی شد. نمودارهای دوبعدی استفاده شده شامل:

- **Scatter Plot**: برای نمایش همبستگی بین قیمت باز شدن و بسته شدن یا قیمت‌ها و حجم معاملات.
- **Correlation Heatmap**: برای بررسی همبستگی کلی بین تمام ستون‌ها.

نتایج:

- همبستگی قوی بین **Open** و **Close**: در هر سه ETF مشاهده شد.
- ارتباط ضعیف بین **Volume** و قیمت‌ها: به‌ویژه در ETF های VT و QQQ.
- **GLD**: نشان داد که حجم معاملات تأثیر کمتری بر قیمت طلا دارد.

۴.۴ تحلیل سه‌بعدی (3D Analysis)

تعامل متغیرها:

برای درک بهتر تعامل میان سه متغیر کلیدی، نمودارهای سه‌بعدی (3D Scatter, 3D Bar) برای هر ETF رسم شدند. متغیرهای بررسی شده شامل:

- **Open, Close و Volume**: برای تحلیل رابطه همزمان میان قیمت باز شدن، قیمت بسته شدن، و حجم معاملات.

نتایج:

- در **VT ETF**: رفتار قیمت‌ها و حجم معاملات نسبتاً متعادل بود.
- در **GLD ETF**: قیمت‌ها مستقل از حجم معاملات رفتار می‌کردند.
- در **QQQ ETF**: نوسانات بالا و ارتباط نزدیک‌تر بین قیمت‌ها و حجم مشاهده شد.

۴.۵ تحلیل سری زمانی (Time Series Analysis)

روند قیمت‌ها در طول زمان

قیمت بسته شدن (Close) هر ETF در بازه زمانی موردنظر بررسی شد. برای این منظور، از نمودارهای خطی برای نمایش تغییرات قیمت در طول زمان استفاده شد.

نوسانات (Volatility)

با استفاده از (Rolling Window, ۳۰ روزه)، نوسانات قیمت در طول زمان برای هر ETF محاسبه شد. این تحلیل به شناسایی دوره‌های پرنوسان و کم‌نوسان کمک کرد.

نتایج:

- VT: روندی پایدارتر با نوسانات محدودتر داشت.
- GLD: تغییرات آرام‌تر و مستقل‌تر از عوامل خارجی.
- QQQ: نوسانات بیشتر، نشان‌دهنده رفتار پویاتر سهام فناوری.

۵ خوشه‌بندی

۵.۱ مقدمه‌ای بر خوشه‌بندی

خوشه‌بندی یکی از روش‌های یادگیری ماشین بدون نظارت است که برای گروه‌بندی داده‌ها بر اساس شباهت‌ها یا الگوهای موجود در آن‌ها استفاده می‌شود. در این پروژه، هدف از خوشه‌بندی، شناسایی الگوهای رفتاری مختلف در ETF ها و بررسی تفاوت‌های کلیدی بین آن‌ها بود. از الگوریتم **K-Means Clustering** برای خوشه‌بندی استفاده شد.

۵.۲ روش خوشه‌بندی

الگوریتم K-Means

الگوریتم K-Means داده‌ها را به K خوشه تقسیم می‌کند، به گونه‌ای که داده‌های داخل هر خوشه شباهت بیشتری به مرکز آن خوشه داشته باشند. مراحل اصلی این الگوریتم عبارت‌اند از:

۱. انتخاب تعداد خوشه‌ها (K).
۲. مقداردهی اولیه مراکز خوشه‌ها.
۳. اختصاص هر نقطه داده به نزدیک‌ترین مرکز خوشه.
۴. به‌روزرسانی مراکز خوشه‌ها بر اساس میانگین نقاط داده در هر خوشه.
۵. تکرار مراحل ۳ و ۴ تا زمانی که مراکز خوشه‌ها ثابت شوند.

۵.۳ تعیین تعداد خوشه‌ها

روش Elbow

برای تعیین تعداد بهینه خوشه‌ها، از روش **Elbow** استفاده شد. این روش بر اساس مقدار مجموع مربعات خطا (SSE) برای تعداد مختلف خوشه‌ها عمل می‌کند. نقطه‌ای که نمودار تغییرات SSE به حالت پایدار می‌رسد، به عنوان تعداد بهینه خوشه‌ها انتخاب می‌شود.

نتایج:

- با استفاده از روش **Elbow**، تعداد بهینه خوشه‌ها برای داده‌های ما ۲ یا ۳ تعیین شد. انتخاب این تعداد بر اساس الگوهای مشاهده‌شده در هر ETF انجام شد.

۵.۴ اجرای خوشه‌بندی برای ETF ها

متغیرهای مورد استفاده در خوشه‌بندی

برای خوشه‌بندی داده‌ها، متغیرهای زیر انتخاب شدند:

- **قیمت باز شدن (Open):** برای شناسایی رفتار ابتدایی بازار.
- **قیمت بسته شدن (Close):** برای بررسی تغییرات نهایی بازار.
- **حجم معاملات (Volume):** برای تحلیل تأثیر حجم بر رفتار کلی.

اجرای الگوریتم K-Means

الگوریتم K-Means روی داده‌های هر ETF به صورت جداگانه اجرا شد:

- داده‌ها با استفاده از **Min-Max Scaling** نرمال‌سازی شدند.
- K-Means با تعداد خوشه‌های بهینه (۲ یا ۳) اجرا شد.

۵.۵ نتایج خوشه‌بندی

ETF VT

- **تعداد خوشه‌ها: ۲**
- **تحلیل خوشه‌ها:**
 - خوشه اول: رفتار پایدارتر با تغییرات محدودتر در قیمت.
 - خوشه دوم: نوسانات بیشتر، اما همچنان با ثبات نسبی.
- **ویژگی‌ها VT:** به دلیل رفتار پایدار کلی، به دو خوشه کلی تقسیم شد.

ETF GLD

- **تعداد خوشه‌ها: ۲**
- **تحلیل خوشه‌ها:**
 - خوشه اول: دوره‌های ثبات قیمتی و حجم معاملات کم.
 - خوشه دوم: تغییرات ناگهانی در قیمت، احتمالاً تحت تأثیر عوامل خارجی.
- **ویژگی‌ها GLD:** نوسانات کمتری نسبت به سایر ETF ها داشت و خوشه‌ها نمایانگر دوره‌های ثبات و تغییر قیمت بودند.

ETF QQQ

- تعداد خوشه‌ها: ۳
- تحلیل خوشه‌ها:
 - خوشه اول: نوسانات متوسط با حجم معاملات زیاد.
 - خوشه دوم: نوسانات کم و قیمت‌های پایدارتر.
 - خوشه سوم: دوره‌های پرنوسان، نشان‌دهنده رفتار ریسک‌پذیر.
- ویژگی‌ها QQQ: بیشترین نوسانات را در بین ETF ها داشت و خوشه‌بندی آن تنوع بالای رفتار قیمت و حجم را نشان داد.

۵.۶ بصری‌سازی نتایج خوشه‌بندی

نمودارهای دوبعدی

- نمایش داده‌ها با توجه به خوشه‌بندی روی محورهای مختلف:
 - Close و Open
 - Volume و Close
- رنگ‌بندی هر خوشه برای شناسایی الگوها.

۵,۶,۲ نمودارهای سه‌بعدی

- استفاده از نمودارهای سه‌بعدی (3D Scatter) برای نمایش خوشه‌بندی بر اساس سه متغیر Open و Close و Volume.

۵.۷ تحلیل کلی خوشه‌بندی

تفاوت ETF ها در خوشه‌بندی:

۱. VT: رفتار پایدار و خوشه‌بندی ساده‌تر.
۲. GLD: خوشه‌بندی بر اساس تغییرات ناگهانی در قیمت طلا.
۳. QQQ: خوشه‌بندی متنوع‌تر با بازتاب نوسانات بالاتر.

نکات کلیدی:

- ETF هایی با نوسانات پایین‌تر (مانند GLD و VT) خوشه‌بندی ساده‌تری داشتند.
- ETF های پرنوسان (مانند QQQ) خوشه‌بندی پیچیده‌تر و رفتار پویاتری نشان دادند.

۶ مقایسه ETF ها

۶.۱ مقدمه

در این فصل، نتایج تحلیل و خوشه‌بندی سه ETF منتخب (VT، GLD، و QQQ) با یکدیگر مقایسه می‌شوند. هدف از این مقایسه شناسایی تفاوت‌ها و شباهت‌های کلیدی میان این ETF ها از نظر بازدهی، نوسانات، همبستگی، و روندهای قیمتی است. این مقایسه به ما کمک می‌کند تا الگوهای رفتاری این ETF ها را بهتر درک کرده و بر اساس آن پیشنهادات سرمایه‌گذاری ارائه دهیم.

۶.۲ مقایسه بازدهی^۱

محاسبه بازدهی کل

بازدهی کل هر ETF بر اساس تغییرات قیمت بسته شدن (Close) از اولین روز تا آخرین روز دوره زمانی محاسبه شد.

نتایج:

- VT: بازدهی پایدار اما متوسط را نشان داد که نمایانگر رفتار شاخص‌های جهانی است.
- GLD: بازدهی پایین‌تر، اما ثابت، نشان‌دهنده نقش طلا به‌عنوان یک دارایی امن.
- QQQ: بیشترین بازدهی را داشت، اما با نوسانات بالاتر همراه بود، که نشان‌دهنده پویایی سهام فناوری است.

۶.۳ مقایسه نوسانات^۲

نوسانات کلی

برای هر ETF، نوسانات کلی قیمت‌ها (بر اساس انحراف استاندارد ستون Close) محاسبه و مقایسه شد.

نوسانات دسته‌ای

نوسانات قیمت بر اساس دسته‌بندی Close_category برای هر ETF بررسی شد.

نوسانات زمانی

نوسانات ۳۰ روزه (Rolling Volatility) برای هر ETF محاسبه و مقایسه شد.

نتایج:

- VT: نوسانات کمتر و رفتار پایدارتر، که نمایانگر عملکرد یکنواخت شاخص‌های جهانی است.
- GLD: کمترین نوسانات، که نشان‌دهنده ثبات بازار طلا است.

¹ Total Returns

² Volatility

- **QQQ**: بیشترین نوسانات، به دلیل ماهیت پویا و حساسیت بالای سهام فناوری.

۶.۴ مقایسه روندهای قیمتی^۱

روندهای قیمتی در طول زمان

قیمت بسته شدن (Close) برای هر ETF در بازه زمانی بررسی و مقایسه شد:

- **VT**: روندی یکنواخت با رشد تدریجی.
- **GLD**: تغییرات جزئی در بازه‌های زمانی مختلف، نشان‌دهنده نقش طلا به عنوان یک دارایی محافظ.
- **QQQ**: رشد سریع‌تر با نوسانات بالاتر.

رفتار در بحران‌های اقتصادی

تحلیل روندهای قیمتی نشان داد که GLD در زمان بحران‌های اقتصادی (مانند سقوط بازارها) رفتار پایدارتری داشته است، در حالی که QQQ و VT نوسانات بیشتری را تجربه کرده‌اند.

۶.۵ مقایسه همبستگی^۲

همبستگی میان ETF ها

ماتریس همبستگی برای ستون‌های Close هر ETF محاسبه شد.

نتایج:

- **VT و QQQ**: همبستگی مثبت قوی داشتند، که نشان‌دهنده تأثیرپذیری از بازارهای سهام جهانی است.
- **GLD و سایر ETF ها**: همبستگی کمتری داشت، که نشان‌دهنده استقلال طلا از بازارهای سهام است.

۶.۶ تحلیل خوشه‌بندی

مقایسه خوشه‌ها

خوشه‌بندی داده‌ها با الگوریتم K-Means تفاوت‌های کلیدی در رفتار ETF ها را نشان داد:

- **VT**: خوشه‌ها نمایانگر رفتار پایدار بازارهای جهانی.
- **GLD**: خوشه‌بندی ساده‌تر با تمرکز بر دوره‌های ثبات و تغییرات جزئی.
- **QQQ**: خوشه‌ها بازتاب‌دهنده نوسانات بالاتر و تنوع رفتار قیمت‌ها.

¹ Price Trends

² Correlation

تحلیل تفاوت خوشه‌ها

GLD بیشتر به ثبات در شرایط مختلف اشاره داشت.

- QQQ تنوع بیشتری را در رفتار خوشه‌ها نشان داد.
- VT بین ثبات و تغییرات تدریجی تقسیم شد.

۶.۷ خلاصه مقایسه

ویژگی	VT	GLD	QQQ
بازدهی کل	متوسط	کم	بالا
نوسانات	کم	بسیار کم	بالا
همبستگی	با QQQ بالا	کم با سایرین	با VT بالا
رفتار کلی	پایدار و یکنواخت	ثبات در شرایط بحرانی	پویا و پرنوسان

۶.۸ نتیجه‌گیری

۱. **ETF پایدارترین** GLD: به دلیل ثبات قیمتی و نوسانات کم، برای سرمایه‌گذاران محافظه‌کار یا در زمان بحران اقتصادی مناسب است.
۲. **ETF پرنوسان‌ترین** QQQ: به دلیل نوسانات بالا و بازدهی بالقوه زیاد، برای سرمایه‌گذاران ریسک‌پذیر جذاب است.
۳. **ETF متعادل** VT: به دلیل رفتار پایدار و رشد تدریجی، برای سرمایه‌گذارانی که به دنبال تعادل میان ریسک و بازدهی هستند، مناسب است.

