

# به نام خدا

موضوع انتخابی پروژه:

تحلیل اکتشافی داده‌ها بر روی مجموعه داده بورس

نام درس: علوم داده

اعضای گروه: نیوشا یقینی، غزل عربعلی

تاریخ: آبان/1403

## فهرست مطالب

|   |                                      |
|---|--------------------------------------|
| ۳ | ۱. EDA چیست؟.....                    |
| ۴ | ۲. مجموعه داده (Dataset).....        |
| ۵ | ۳. روش‌های اعمال EDA.....            |
| ۷ | ۴. ابزارها و کتابخانه‌ها.....        |
| ۸ | ۵. پروژه‌های مشابه و منابع مرجع..... |

## 1. EDA چیست؟

### 1.1. شرح موضوع و اهمیت EDA

تحلیل اکتشافی داده‌ها یا **Exploratory Data Analysis (EDA)**، اولین مرحله از فرآیند تحلیل داده است که برای بررسی و درک بهتر ویژگی‌های مختلف داده‌ها مورد استفاده قرار می‌گیرد. EDA، به تحلیل‌گران و پژوهشگران کمک می‌کند تا داده‌ها را بهتر درک کنند، روابط پنهان و الگوهای احتمالی را کشف کنند و مشکلات یا نواقص موجود در داده‌ها، مانند مقادیر خالی یا ناهنجاری‌ها را شناسایی نمایند. اهمیت EDA در این است که به‌عنوان پایه‌ای قوی برای مراحل بعدی تحلیل، از جمله مدل‌سازی یا یادگیری ماشین، عمل می‌کند و کمک می‌کند تصمیم‌های مناسبی برای پردازش و استفاده از داده‌ها اتخاذ شود.

### 1.2. معرفی EDA و اهداف آن در تحلیل داده‌ها

EDA شامل استفاده از ابزارها و روش‌های مختلفی برای تجزیه و تحلیل آماری، تجسم داده‌ها، و پاک‌سازی داده‌ها است. اهداف اصلی EDA عبارت‌اند از:

1. خلاصه‌سازی داده‌ها: کمک به تحلیل‌گران برای درک بهتر ویژگی‌ها و خصوصیات داده‌ها از طریق محاسبه آماره‌های توصیفی مانند میانگین، انحراف معیار و توزیع.
2. شناسایی روابط بین متغیرها: کشف روابط و همبستگی‌های پنهان بین متغیرها که می‌تواند به تولید فرضیه‌های جدید یا تحلیل‌های دقیق‌تر منجر شود.
3. تشخیص الگوها و ناهنجاری‌ها: شناسایی ترندها الگوهای فصلی و نقاط ناهنجار که ممکن است برای تحلیل‌های بیشتر یا تصمیم‌گیری‌ها مفید باشند.
4. آماده‌سازی داده‌ها برای مراحل بعدی EDA: به‌عنوان مرحله‌ای از پیش‌پردازش داده‌ها به کاهش نویز، شناسایی و حذف داده‌های مشکل‌دار، و تبدیل داده‌ها به فرمت مناسب کمک می‌کند.

### 1.3. اهداف EDA در این پروژه

در این پروژه، هدف از انجام EDA بر روی داده‌های بورس، کسب شناختی عمیق از ساختار و ویژگی‌های این داده‌ها است. این اهداف شامل موارد زیر می‌شود:

- شناسایی الگوهای قیمتی و نوسانات بازار: بررسی تغییرات قیمت سهام در بازه‌های زمانی مختلف و شناسایی روندها.
- تحلیل نوسانات و حجم معاملات: درک بهتر از ارتباط بین حجم معاملات و تغییرات قیمتی برای شناسایی روزهای پرتلاطم بازار.
- کشف روابط و همبستگی‌های احتمالی: شناسایی روابط بین ویژگی‌های مختلف داده‌ها، مانند قیمت‌های باز و بسته، یا حجم معاملات و تغییرات قیمت.

انجام EDA در این پروژه، اطلاعات ارزشمندی را فراهم می‌کند که می‌تواند به تصمیم‌گیری‌ها و تحلیل‌های دقیق‌تر کمک کند.

## 2. مجموعه داده (Dataset):

### 2.1. معرفی مجموعه داده

مجموعه داده‌ی مورد استفاده برای این پروژه، شامل اطلاعات قیمت و حجم معاملات برای تمامی سهام و ETF های ایالات متحده است. این مجموعه داده از **Kaggle** دریافت شده و یکی از منابع ارزشمند برای تحلیل‌های مالی و بازار سرمایه به شمار می‌رود. هدف اصلی از انتخاب این مجموعه داده، بررسی روندها و تحلیل نوسانات قیمتی و حجم معاملات در بازه‌های زمانی مختلف است. این داده‌ها به‌ویژه برای شناسایی ترندهای بازار، بررسی تغییرات قیمتی، و تحلیل حجم معاملات در روزهای مختلف مفید هستند.

### 2.2. مشخصات داده‌ها

این مجموعه داده به صورت تعدادی فایل CSV ارائه شده که هر فایل نمایانگر داده‌های تاریخی مرتبط با یک نماد خاص (سهام یا ETF) است. هر فایل معمولاً شامل ستون‌های زیر است:

- **Date (تاریخ):** تاریخ معامله در هر روز.
- **Open (قیمت باز شدن):** قیمت سهام یا ETF در ابتدای روز معاملاتی.
- **High (بالا ترین قیمت):** بیشترین قیمت ثبت شده در طول روز معاملاتی.
- **Low (پایین ترین قیمت):** کمترین قیمت ثبت شده در طول روز معاملاتی.
- **Close (قیمت بسته شدن):** قیمت سهام یا ETF در پایان روز معاملاتی.
- **Volume (حجم معاملات):** تعداد سهام معامله شده در آن روز.

این ساختار، امکان تجزیه و تحلیل جامعی از تغییرات قیمتی و حجم معاملات را فراهم می‌کند و به تحلیل‌گران اجازه می‌دهد تا الگوهای مختلف بازار و نوسانات قیمتی را درک کنند.

منبع برای دیتاست:

<https://www.kaggle.com/datasets/borismarjanovic/price-volume-data-for-all-us-stocks-etfs>

### 3. روش‌های اعمال EDA:

#### 3.1. روش‌های پاک‌سازی داده‌ها

برای آغاز تحلیل اکتشافی، اولین گام پاک‌سازی و آماده‌سازی داده‌ها است. مراحل اصلی شامل موارد زیر هستند:

- **شناسایی و مدیریت مقادیر خالی:** بررسی وجود داده‌های خالی در ستون‌های مهم مانند قیمت‌های "باز"، "بسته" و "حجم معاملات". این مقادیر می‌توانند با میانگین یا میانگین متحرک جایگزین شوند، یا در صورت اهمیت کم، حذف گردند.
- **بررسی داده‌های نامعتبر یا ناهنجار:** داده‌های غیرمنطقی، مانند قیمت‌های منفی یا بسیار زیاد، باید شناسایی و مدیریت شوند. حذف این مقادیر یا اصلاح آن‌ها می‌تواند به تمیزتر شدن داده‌ها کمک کند.
- **ترتیب زمانی و هماهنگ‌سازی فرمت تاریخ‌ها:** اطمینان از اینکه تمامی تاریخ‌ها در یک فرمت هستند و داده‌ها به ترتیب زمانی مرتب شده‌اند.

#### 3.2. روش‌های آماری

با استفاده از خلاصه‌های آماری می‌توان بینش‌های اولیه‌ای درباره وضعیت داده‌ها به‌دست آورد:

- **محاسبه میانگین، میانه و انحراف معیار:** برای مقایسه و بررسی پراکندگی داده‌ها و شناسایی الگوهای قیمتی میانگین‌ها و پراکندگی‌ها بررسی می‌شود.
- **حداکثر و حداقل قیمت‌ها:** شناسایی روزهای اوج و پایین‌ترین قیمت، که می‌تواند به تحلیل نقاط بحرانی کمک کند.
- **بررسی شاخص‌های آماری بین قیمت‌ها و حجم معاملات:** تحلیل همبستگی بین قیمت‌های باز، بسته، و حجم معاملات برای شناسایی روابط احتمالی.

#### 3.3. تجسم داده‌ها

تجسم داده‌ها برای درک بهتر الگوها و روابط موجود در داده‌ها به کار می‌رود:

- **نمودار خطی برای روند قیمتی:** رسم نمودارهای خطی برای مشاهده روند قیمتی باز و بسته هر سهام در طول زمان.
- **نمودار شمعی (Candlestick Chart):** استفاده از نمودارهای شمعی که برای نمایش قیمت‌های باز، بالا، پایین و بسته در تحلیل تکنیکال بازار بورس بسیار رایج است و به شناسایی روندها و نقاط برگشت کمک می‌کند.
- **هیستوگرام و نمودار چگالی:** نمایش توزیع قیمت‌ها و حجم معاملات در طول زمان برای بررسی توزیع و الگوهای قیمتی.
- **Heatmap برای همبستگی:** استفاده از نقشه‌های گرمایی برای بررسی همبستگی بین متغیرهای مختلف مانند قیمت‌های باز، بسته، حجم معاملات و دیگر متغیرها.

### 3.4. تحلیل سری زمانی

تحلیل سری زمانی به بررسی روندهای کوتاه‌مدت و بلندمدت در داده‌های تاریخی می‌پردازد:

- **میانگین متحرک ساده و نمایی:** استفاده از میانگین‌های متحرک برای شناسایی روندهای بلندمدت و کوتاه‌مدت و هموارسازی نوسانات.
- **بررسی فصلی بودن (Seasonality):** شناسایی الگوهای تکراری روزانه، هفتگی یا ماهانه، که می‌تواند در داده‌های بورس تأثیرات معنی‌داری داشته باشد.
- **تحلیل نوسانات و نقاط ناهنجار:** شناسایی نوسانات ناگهانی قیمت‌ها یا حجم معاملات برای شناسایی روزهای پرتلاطم و بررسی تغییرات قیمتی غیرمنتظره.

این روش‌های EDA برای بررسی جامع و شناخت بهتر داده‌های بورس به کار گرفته می‌شوند.

## 4. ابزارها و کتابخانه‌ها:

### 4.1. کتابخانه‌های پایتون

در این پروژه برای انجام تحلیل اکتشافی داده‌ها (EDA) و تجسم آن‌ها، از چندین کتابخانه‌ی معروف و قدرتمند پایتون استفاده می‌شود:

- **Pandas**: این کتابخانه به‌عنوان اصلی‌ترین ابزار برای پردازش و مدیریت داده‌ها در پایتون به کار می‌رود. Pandas امکاناتی برای خواندن داده‌ها، پاک‌سازی، خلاصه‌سازی، و انجام تحلیل‌های آماری ابتدایی فراهم می‌کند. همچنین، قابلیت‌های این کتابخانه برای پردازش داده‌های سری زمانی و تجزیه و تحلیل داده‌ها، آن را برای کار با داده‌های مالی بسیار مناسب می‌سازد.
- **Matplotlib**: این کتابخانه اصلی‌ترین ابزار تجسم داده‌ها در پایتون است و امکان ایجاد نمودارهای خطی، هیستوگرام، نمودارهای پراکندگی و غیره را فراهم می‌کند. Matplotlib برای رسم نمودارهای شمعی که در تحلیل‌های تکنیکال بازارهای مالی استفاده می‌شود نیز گزینه‌ای مناسب است.
- **Seaborn**: یک کتابخانه تجسم داده پیشرفته بر اساس Matplotlib است که تجسم‌های زیباتر و کاربردی‌تر را ارائه می‌دهد. Seaborn امکان ایجاد نمودارهای گرمایی (Heatmap) برای تحلیل همبستگی بین متغیرها، نمودارهای جعبه‌ای، و نمودارهای چگالی را فراهم می‌کند که در تحلیل بازارهای مالی کاربرد زیادی دارند.
- **Plotly**: یک کتابخانه تجسم داده تعاملی است که برای ایجاد نمودارهای تعاملی، از جمله نمودارهای شمعی و سری زمانی، بسیار مناسب است. Plotly به‌ویژه برای تحلیل داده‌های مالی و بصری‌سازی تغییرات قیمت در بازه‌های مختلف زمانی مفید است.

### 4.2. سایر ابزارها

در صورت نیاز به تجسم‌های پیشرفته‌تر و تعامل بیشتر با داده‌ها، از ابزارهای دیگری نیز می‌توان بهره برد:

- **Tableau**: برای ایجاد داشبوردهای تعاملی و تجسم داده‌ها با امکانات بیشتر، نرم‌افزار Tableau گزینه‌ی مناسبی است. Tableau امکان تحلیل و ارائه داده‌ها را به شکل بصری و قابل فهم فراهم می‌کند و به‌ویژه برای گزارش‌دهی و ارائه یافته‌ها کاربرد دارد.
- **Excel**: برای تحلیل‌های ساده و ارائه گزارش‌های اولیه، استفاده از Excel به دلیل سادگی و قابلیت‌های گسترده آن در تجزیه و تحلیل داده‌ها می‌تواند مفید باشد. Excel به‌ویژه برای انجام عملیات اولیه آماری و ساخت نمودارهای ساده مناسب است.

این ابزارها و کتابخانه‌ها کمک می‌کنند تا تحلیل داده‌های مالی را به‌صورت جامع و دقیق انجام داده و نتایجمان را به شکل بصری و قابل فهم ارائه دهیم.

## 5. پروژه‌های مشابه و منابع مرجع:

برای تقویت پروژه تحلیل اکتشافی داده‌ها (EDA) در حوزه بورس، نمونه‌های موجود در GitHub می‌توانند به‌عنوان منابع مفیدی در اختیار باشند. این پروژه‌ها از روش‌ها و تکنیک‌های مختلف برای تحلیل داده‌های مالی استفاده کرده‌اند و می‌توانند به‌عنوان مرجع و الهام‌بخش برای پیاده‌سازی و پیشبرد پروژه ما عمل کنند. در ادامه، چند نمونه مرتبط و کاربردی معرفی می‌شود:

- **Stock Market Analysis and Prediction**

این پروژه به تحلیل و پیش‌بینی بازار سهام با استفاده از EDA، تجسم داده‌ها و تحلیل‌های پیش‌بینی می‌پردازد. داده‌های مورد استفاده از The Investors Exchange (IEX) استخراج شده‌اند.

<https://github.com/anwarcsebd/stock-market-analysis>

- **Stock Market Exploratory Data Analytics (EDA) Project Documentation**

این پروژه شامل مستندات مربوط به تحلیل اکتشافی داده‌های بازار سهام است که با استفاده از زبان برنامه‌نویسی R انجام شده است.

<https://github.com/linto94/Stock-Market-EDA-Project-Documentation>

- **EDA-Project-on-Stock-Market**

این پروژه به تجسم، استخراج الگوها و تحلیل روزانه قیمت‌ها و حجم معاملات سهام می‌پردازد و از کتابخانه‌های پایتون برای تحلیل داده‌ها استفاده می‌کند.

<https://github.com/rutika3084/EDA-Project-on-Stock-Market>

- **EDA-stock\_market**

این پروژه به تحلیل اکتشافی داده‌های مالی از چهار شرکت فناوری می‌پردازد و تلاش می‌کند روندهای سهام را پیش‌بینی کند.

[https://github.com/ananupam/EDA-stock\\_market](https://github.com/ananupam/EDA-stock_market)

- **EDA-on-Stock-Market**

این پروژه به تحلیل اکتشافی داده‌های قیمت سهام یک شرکت می‌پردازد و از روش‌های مختلف برای بررسی داده‌ها استفاده می‌کند.

<https://github.com/ArifDeen/EDA-on-Stock-Market>